Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»
ИНСТИТУТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ И ИНТЕЛЛЕКТУАЛЬНЫХ СИСТЕМ

Направление подготовки: 09.03.04 – Программная инженерия
Профиль: Современная разработка программного обеспечения

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Разработка веб-сервиса для диагностики и оценки рисков пневмонии по рентгеновском снимкам и клиническим данным с помощью методов машинного обучения

Обучающийся 4 курса
группы 11-200 Абдельгаффар А.А.М.

Научный руководитель
к. т. н., старший преподаватель кафедры
программной инженерии Мухамеджанов А. И.

Директор ИТИС КФУ
канд. техн. наук Абрамский М.М.

Казань – 2026

СОДЕРЖАНИЕ

СОДЕРЖАНИЕ **2**
ГЛОССАРИЙ **4**
ВВЕДЕНИЕ **9**
ГЛАВА 1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ РЕШЕНИЙ **12**
1.1. Особенности диагностики пневмонии по рентгеновским снимкам 12
1.2. Подходы к классификации рентгеновских изображений 13
1.3. Набор данных Chest X-Ray Pneumonia Dataset 14
1.4. Дополнительный модуль оценки состояния пациента 15
1.5. Анализ существующих решений 16
ГЛАВА 2. РАЗРАБОТКА И ОБУЧЕНИЕ МОДЕЛЕЙ МАШИННОГО ОБУЧЕНИЯ **18**
2.1. Подготовка датасета 18
2.2. Предварительная обработка изображений 20
2.3. Аугментация данных 21
2.4. Обучение моделей 22
2.5. Модель DenseNet121 22
2.6. Модель EfficientNetB0 25
2.7. Модель ResNet50 26
2.8. Модель MobileNetV2 27
2.9. Базовая модель сверточной нейронной сети (CNN) 28
2.10. Оценка качества моделей 31
ГЛАВА 3. РАЗРАБОТКА ПРОГРАММНОЙ СИСТЕМЫ АНАЛИЗА МЕДИЦИНСКИХ ИЗОБРАЖЕНИЙ **33**
3.1. Общая архитектура системы 33
3.2. Клиентская часть системы 34
3.2.1. Страница авторизации пользователей 34
3.2.2. Страница регистрации пользователей 36
3.2.3. Главная страница системы 37
3.2.4. Отображение результатов анализа 38
3.2.5. Формирование пояснительного текста и ИИ ассистента 39
3.2.6. Визуализация областей внимания модели 40
3.2.7. Страница регистрации пациента 41
3.2.8. Страница управления пациентами 42
3.2.9. Карточка пациента 43

3.2.10. Страница истории исследований 44
3.2.11. Страница последующего наблюдения пациента 45
3.2.12. Страница консультаций 46
3.2.13. Страница статистики и аналитики 47
3.2.14. Страница профиля пользователя 49
3.3. Серверная часть приложения 50
3.3.1. Система аутентификации и авторизации 50
3.3.2. Модуль анализа медицинских изображений 51
3.3.3. Модуль формирования пояснительного текста 53
3.3.4. Интеграция ИИ ассистента 54
3.3.5. Модуль генерации тепловой карты 54
3.3.6. Модули управления пациентами 55
3.3.7. Модуль управления медицинскими записями 56
3.3.8. Модуль анализа медицинской записи пациента 57
3.3.9. Модуль истории исследований 57
3.3.10. Модуль управления последующим наблюдением пациентов 58
3.3.11. Модуль консультаций 59
3.3.12. Модуль статистики 60
3.4. Интеграция модели машинного обучения 61
3.5. Оценка степени тяжести с использованием шкалы CURB-65 61
3.6. База данных системы 62
3.7. Система сравнения результатов исследований 64
3.8. Настольная версия системы 65
3.9. Ограничения исследования 66
ЗАКЛЮЧЕНИЕ 67
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 69
Приложение 73

ГЛОССАРИЙ

- **Искусственный интеллект (Artificial Intelligence, AI)** — направление информатики, занимающееся созданием алгоритмов и программных систем, способных выполнять задачи, которые обычно требуют человеческого интеллекта, например анализ данных, распознавание изображений и принятие решений.
- **Машинное обучение (Machine Learning)** — раздел искусственного интеллекта, изучающий методы построения алгоритмов, которые способны обучаться на основе данных и со временем улучшать точность своих предсказаний без прямого программирования каждого шага.
- **Глубокое обучение (Deep Learning)** — область машинного обучения, основанная на использовании многослойных нейронных сетей. Такие модели способны автоматически извлекать сложные признаки из данных, включая изображения, текст и аудио.
- **Нейронная сеть** — математическая модель, вдохновлённая структурой биологических нейронных сетей. Она состоит из взаимосвязанных вычислительных элементов (нейронов), которые обрабатывают входные данные и формируют предсказания.
- **Сверточная нейронная сеть (Convolutional Neural Network, CNN)** — тип нейронной сети, разработанный специально для анализа изображений. Такие сети используют операции свёртки для извлечения пространственных признаков из изображений.
- **Transfer Learning (перенос обучения)** — метод машинного обучения, при котором модель, ранее обученная на большом наборе данных, используется как основа для решения новой задачи. Это позволяет существенно сократить время обучения и повысить точность модели.

- **DenseNet121** — архитектура глубокой сверточной нейронной сети, в которой каждый слой связан со всеми предыдущими слоями. Такая структура улучшает передачу информации между слоями и способствует более эффективному обучению модели.
- **ResNet50** — архитектура нейронной сети, основанная на использовании остаточных связей (residual connections). Эти связи помогают обучать глубокие сети без возникновения проблемы затухающих градиентов.
- **MobileNet** — облегчённая архитектура нейронной сети, оптимизированная для работы на устройствах с ограниченными вычислительными ресурсами. Используется для задач компьютерного зрения, где важна высокая скорость обработки.
- **EfficientNet** — современная архитектура нейронной сети, которая обеспечивает высокую точность классификации изображений при сравнительно низких вычислительных затратах.
- **TensorFlow** — библиотека машинного обучения с открытым исходным кодом, разработанная компанией Google. Она предоставляет инструменты для создания и обучения нейронных сетей различной сложности.
- **Keras** — высокоуровневый интерфейс для работы с нейронными сетями, который используется поверх TensorFlow. Он упрощает процесс разработки и обучения моделей глубокого обучения.
- **PyTorch** — популярная библиотека машинного обучения, предоставляющая инструменты для создания и обучения нейронных сетей. Широко используется в научных исследованиях и разработке моделей искусственного интеллекта.
- **NumPy** — библиотека языка Python для выполнения численных вычислений. Она используется для работы с многомерными массивами и математическими операциями.

- **OpenCV** — библиотека компьютерного зрения, предназначенная для обработки изображений и видео. Используется для подготовки и преобразования изображений перед обучением моделей.
- **Matplotlib** — библиотека для визуализации данных на языке Python. Она применяется для отображения графиков и результатов обучения моделей.
- **Scikit-learn** — библиотека машинного обучения для языка Python, содержащая различные алгоритмы анализа данных и инструменты для оценки качества моделей.
- **Датасет (Dataset)** — структурированный набор данных, используемый для обучения и тестирования моделей машинного обучения.
- **KaggleHub —** платформа для доступа к наборам данных и участия в соревнованиях по анализу данных.
- **Аугментация данных (Data Augmentation)** — метод увеличения объема обучающих данных путем применения различных преобразований изображений, таких как поворот, масштабирование или отражение.
- **Классификация изображений** — задача машинного обучения, при которой алгоритм определяет, к какому классу относится изображение.
- **Метрики качества —** показатели, используемые для оценки моделей: Accuracy, Precision, Recall, F1-Score.
- **Рентгеновское изображение (X-ray)** — медицинское изображение, получаемое с помощью рентгеновского излучения и позволяющее визуализировать внутренние структуры организма.
- **Пневмония** — воспалительное заболевание лёгких, характеризующееся поражением альвеол и накоплением жидкости в легочной ткани.

- **ONNX (Open Neural Network Exchange)** — открытый формат представления моделей машинного обучения, предназначенный для переноса моделей между различными фреймворками и платформами.
- **ONNX Runtime** — программная библиотека для выполнения моделей машинного обучения в формате ONNX с высокой производительностью.
- **Инференс (Inference)** — процесс применения обученной модели машинного обучения для получения предсказаний на новых данных.
- **API (Application Programming Interface)** — программный интерфейс, позволяющий различным программным компонентам взаимодействовать друг с другом и обмениваться данными.
- **Next.js** — современный фреймворк для разработки веб-приложений на основе JavaScript и TypeScript, который поддерживает серверную обработку данных и создание API.
- **Node.js** — программная платформа, позволяющая выполнять JavaScript-код на стороне сервера.
- **TypeScript** — расширение языка JavaScript, добавляющее статическую типизацию и позволяющее создавать более надежные и масштабируемые приложения.
- **Tailwind CSS** — современный CSS-фреймворк, позволяющий быстро создавать пользовательские интерфейсы с помощью готовых классов стилей.
- **PostgreSQL** — реляционная система управления базами данных с открытым исходным кодом, предназначенная для хранения и обработки структурированных данных.
- **pgAdmin** — инструмент администрирования баз данных PostgreSQL, позволяющий управлять базами данных через графический интерфейс.

- **Supabase** — облачная платформа, предоставляющая инструменты для работы с базами данных, аутентификации пользователей и хранения данных.
- **Ollama** — программная среда для локального запуска больших языковых моделей, используемых для обработки текстовой информации и генерации ответов.
- **Qwen** — языковая модель искусственного интеллекта, предназначенная для обработки естественного языка и генерации текстовых рекомендаций.
- **jsPDF** — библиотека JavaScript, предназначенная для создания и генерации PDF-документов непосредственно в веб-приложении.
- **ElectronJS** — платформа для разработки настольных приложений на основе веб-технологий, таких как HTML, CSS и JavaScript.
- **Веб-приложение** — программная система, доступ к которой осуществляется через веб-браузер и которая работает на основе клиент-серверной архитектуры.
- **Серверная часть системы** — программный компонент, который обрабатывает запросы пользователей, выполняет вычисления и взаимодействует с базой данных.
- **Клиентская часть системы** — пользовательский интерфейс приложения, через который пользователь взаимодействует с системой.

ВВЕДЕНИЕ

Пневмония относится к числу наиболее распространенных заболеваний органов дыхания и по-прежнему остаётся одной из серьезных причин смертности во многих странах мира. Наибольшему риску подвержены дети, пожилые люди и пациенты с ослабленной иммунной системой. При этом эффективность лечения во многом зависит от того, насколько быстро заболевание будет выявлено и насколько своевременно пациент получит необходимую медицинскую помощь.

По данным проекта Our World in Data за 2023 год, пневмония и другие инфекции нижних дыхательных путей продолжают занимать значимое место среди причин смертности населения. Наибольшее число летальных исходов было зафиксировано в Индии более 412 тысяч случаев. Высокие показатели также наблюдались в Китае (около 170 тысяч случаев) и Нигерии (более 146 тысяч случаев). Эти данные подтверждают необходимость дальнейшего совершенствования методов диагностики заболеваний лёгких и разработки современных программных средств, способных помочь специалистам при анализе медицинских изображений.

Одним из основных методов первичного обследования пациентов с подозрением на пневмонию является рентгенография грудной клетки. Данный метод широко используется в медицинской практике благодаря своей доступности и относительной простоте проведения. Анализ рентгеновских снимков позволяет выявлять воспалительные изменения легочной ткани и другие признаки патологических процессов. Однако интерпретация результатов во многом зависит от квалификации специалиста, а при большом количестве исследований нагрузка на врача существенно возрастает.

В условиях увеличения объёма диагностических исследований всё больший интерес представляют системы автоматизированного анализа медицинских изображений. Такие системы могут использоваться в качестве

вспомогательного инструмента, позволяющего ускорить обработку снимков и предоставить врачу дополнительную информацию для принятия решений.

В последние годы для решения подобных задач активно применяются методы глубокого обучения и сверточные нейронные сети. Современные модели способны автоматически выделять характерные признаки на изображениях и выполнять их классификацию с высокой точностью. Благодаря этому технологии машинного обучения всё чаще используются в медицинских информационных системах и исследовательских проектах, связанных с анализом рентгеновских изображений.

Актуальность работы обусловлена необходимостью разработки программной системы, которая объединяет автоматический анализ рентгеновских изображений, хранение результатов исследований и дополнительные инструменты поддержки процесса диагностики.

Целью работы является разработка программной системы анализа рентгеновских изображений грудной клетки для выявления признаков пневмонии с использованием методов глубокого обучения.

Для достижения этой цели были поставлены **следующие задачи:**

1. Провести анализ альтернативных решений для анализа рентгеновских изображений грудной клетки.
2. Реализовать и обучить несколько моделей машинного обучения для классификации рентгеновских изображений грудной клетки.
3. Подготовить и экспортировать обученную модель в формате ONNX для использования в веб-приложении.
4. Разработать серверную часть приложения для обработки рентгеновских изображений и выполнения анализа.
5. Разработать и реализовать пользовательский интерфейс для загрузки изображений и отображения результатов.
6. Реализовать систему хранения медицинских данных, пациентов и истории исследований.

7. Реализовать модуль расчёта клинической шкалы CURB-65 на основе вводимых пользователем параметров.
8. Разработать модуль формирования пояснительного текста для интерпретации результатов анализа.
9. Реализовать механизм генерации тепловых карт для визуализации областей анализа изображения.
10. Провести оценку качества разработанной модели и программной системы.

ГЛАВА 1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ РЕШЕНИЙ

1.1. Особенности диагностики пневмонии по рентгеновским снимкам

Пневмония является одним из наиболее распространённых заболеваний органов дыхания и продолжает оставаться серьёзной медицинской проблемой во многих странах мира. Наибольший риск тяжелого течения заболевания наблюдается у пожилых людей, пациентов с ослабленным иммунитетом и детей. В таких условиях своевременная диагностика играет важную роль, поскольку позволяет раньше начать лечение и снизить вероятность развития осложнений [1].

Одним из основных методов первичной диагностики является рентгенография грудной клетки. Этот метод широко применяется в медицинской практике благодаря своей доступности, относительно невысокой стоимости и возможности быстрого получения результатов. Анализ рентгеновских снимков позволяет выявлять воспалительные изменения легочной ткани, участки затемнения и другие признаки, характерные для различных заболеваний органов дыхания [1].

Несмотря на распространённость данного метода, интерпретация рентгеновских изображений остается непростой задачей. На ранних стадиях заболевания патологические изменения могут быть выражены слабо и не всегда легко обнаруживаются визуально. Кроме того, качество анализа зависит от опыта специалиста и условий его работы. В медицинских учреждениях с большим потоком пациентов врачу нередко приходится просматривать значительное количество исследований за ограниченное время, что увеличивает вероятность пропуска отдельных признаков заболевания.

С точки зрения машинного обучения рентгеновские изображения представляют интересный объект исследования. Относительная

стандартизированность снимков и развитие современных методов компьютерного зрения позволяют использовать алгоритмы глубокого обучения для автоматического выявления признаков патологии и последующей классификации изображений [2, 3].

1.2. Подходы к классификации рентгеновских изображений

В последние годы для анализа медицинских изображений применяются сверточные нейронные сети. Одним из наиболее распространённых подходов является transfer learning, при котором используются предварительно обученные модели, которые адаптированные под конкретную задачу. Такой подход позволяет обучить модели быстрее и добиться высокой точности даже при ограниченном количестве изображений.

При классификации рентгеновских изображений грудной клетки часто используются архитектуры DenseNet, ResNet, EfficientNet и MobileNet. Каждая из них имеет свои особенности и преимущества. Архитектура DenseNet обеспечивает эффективную передачу признаков между слоями сети и хорошо зарекомендовала себя в задачах медицинского анализа изображений [4]. ResNet позволяет использовать более глубокие модели благодаря остаточным соединениям, что помогает избежать деградации качества обучения [5]. EfficientNet ориентирована на достижение высокого качества при разумных вычислительных затратах [6], а MobileNet применяется в случаях, когда важны компактность модели и скорость работы [7].

При выборе модели необходимо учитывать не только метрики точности классификации, но и вычислительные затраты, скорость обработки изображений и возможность дальнейшего использования модели в веб-приложении.

В ходе исследования были рассмотрены несколько архитектур модели машинного обучения. Среди них лучшие результаты показала модель

DenseNet121. Именно она была использована в качестве основной модели разработанной системы.

1.3. Набор данных Chest X-Ray Pneumonia Dataset

Для обучения модели использовался набор данных Chest X-Ray Pneumonia Dataset, из платформы Kaggle на основе работы Kermany et al [8, 9].

Датасет содержит две группы: Normal и Pneumonia. Всего в наборе данных используется 5856 изображений, из которых 1583 относятся к первой группе Normal и 4273 к второй группе Pneumonia [8].

Изображения из датасета разделены автором на обучающую, валидационную и тестовую выборки. Изображения представлены в grayscale-формате и имеют различное качество и уровень контрастности, что делает задачу классификации более приближенной к реальным условиям медицинской практики.

Выбор данного набора данных связан с несколькими факторами. Датасет содержит достаточный объем изображений для обучения моделей машинного обучения и позволяет использовать его в задачах классификации рентгеновских изображений грудной клетки. Это позволяет применять его в качестве benchmark-набора для сравнения результатов различных архитектур.

При этом датасет имеет ряд ограничений. Значительная часть изображений относится к детской выборке пациентов, что ограничивает универсальность модели при использовании на других возрастных группах. Кроме того, наблюдается дисбаланс классов, поскольку количество изображений Pneumonia существенно превышает число снимков класса Normal [9].

Дополнительно при работе с медицинскими изображениями необходимо учитывать риск data leakage при некорректном разделении

выборок. В подобных задачах это может приводить к искусственному завышению метрик классификации.

Несмотря на указанные ограничения, Chest X-Ray Pneumonia Dataset остаётся одним из наиболее распространённых наборов данных для задач автоматического анализа рентгеновских изображений грудной клетки.

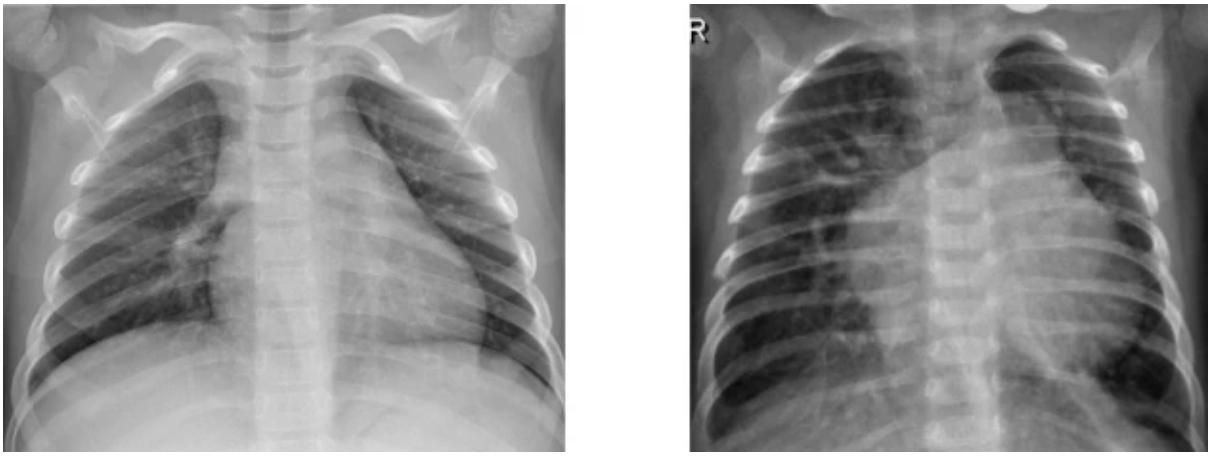


Рисунок 1 — Пример рентгеновского изображения класса Normal/Pneumonia

1.4. Дополнительный модуль оценки состояния пациента

Помимо анализа рентгеновских изображений в системе дополнительно реализован модуль расчёта клинической шкалы CURB-65 [10].

Следует отметить, что CURB-65 не относится к задаче классификации изображений и не вычисляется нейронной сетью. Расчёт выполняется отдельно на основе параметров, вводимых пользователем: уровня мочевины, частоты дыхания, артериального давления, возраста пациента и наличия нарушения сознания.

Использование CURB-65 в рамках системы рассматривается как дополнительный практический инструмент, позволяющий учитывать не только результат анализа изображения, но и клинические показатели пациента.

1.5. Анализ существующих решений

В настоящее время на рынке представлены различные программные решения, использующие технологии искусственного интеллекта для анализа медицинских изображений. Многие из них ориентированы на помощь врачам при интерпретации результатов исследований и автоматическое выявление признаков патологий на рентгеновских снимках.

Среди наиболее известных коммерческих систем можно выделить Qure.ai [11], InferVision [12], Lunit [13] и Aidoc [14].

Qure.ai применяется для автоматического анализа рентгеновских изображений и компьютерной томографии. Платформа позволяет выявлять различные патологии органов грудной клетки и используется в медицинских учреждениях ряда стран.

InferVision представляет собой систему анализа медицинских изображений на основе методов глубокого обучения. Особую известность данное решение получило в период распространения COVID-19, когда активно использовалось для анализа снимков пациентов с заболеваниями лёгких.

Lunit является системой поддержки принятия врачебных решений, предназначенной для обнаружения патологических изменений на рентгеновских изображениях и помощи специалистам при их интерпретации.

Aidoc ориентирована на автоматизированный анализ медицинских данных и позволяет оперативно выделять исследования, требующие повышенного внимания со стороны врача.

Таблица 1 — Сравнение существующих решений

Система	**AI-анализ рентгенов**	**Heatmap**	**Управление пациентами**	**CURB-65**	**Пояснительный текст**
Qure.ai	+	+	–	–	–
InferVision	+	+	–	–	–

Lunit	+	+	–	–	–
Aidoc	+	+	–	–	–

После анализа рассмотренных систем можно сделать вывод, что их основной функционал сосредоточен на автоматическом анализе медицинских изображений и выявлении патологий. Вместе с тем вопросы хранения данных пациентов, ведения истории исследований и дополнительной клинической оценки состояния пациента зачастую остаются за пределами таких решений.

Разрабатываемая система создавалась не только как инструмент классификации рентгеновских снимков. Помимо анализа изображений она обеспечивает хранение данных пациентов и результатов исследований, поддерживает расчёт шкалы CURB-65 и формирование пояснительного текста по итогам анализа. Такой подход позволяет объединить несколько взаимосвязанных инструментов в рамках одной платформы и предоставить врачу более полную информацию для принятия решений.

ГЛАВА 2. РАЗРАБОТКА И ОБУЧЕНИЕ МОДЕЛЕЙ МАШИННОГО ОБУЧЕНИЯ

2.1. Подготовка датасета

В качестве исходных данных использовался набор Chest X-Ray Pneumonia Dataset, опубликованный на платформе Kaggle [8]. Набор данных состоит из рентгеновских изображений грудной клетки, разделенных на две группы:

- NORMAL — изображения без выявленных признаков пневмонии;
- PNEUMONIA — изображения с признаками пневмонии.

Всего набор данных включает 5856 изображений, из которых 1583 относятся к классу NORMAL и 4273 — к классу PNEUMONIA.

При работе с датасетом использовалось разделение выборок, подготовленное его авторами. Распределение изображений между обучающей, валидационной и тестовой выборками приведено в таблице 2.

Таблица 2 – Распределение изображений по выборкам

Выборка	NORMAL	PNEUMONIA	Total
Train	1341	3875	5216
Validation	8	8	16
Test	234	390	624
Total	1583	4273	5856

Для моделей ResNet50 и MobileNetV2 использовалось исходное разделение данных, предоставленное авторами набора данных.

Для моделей DenseNet121 и EfficientNetB0 дополнительно выполнялось пользовательское разделение изображений с использованием функции train_test_split. При этом применялось стратифицированное разделение (stratify), позволяющее сохранить исходное соотношение классов во всех выборках. Данные были разделены следующим образом:

- 80% — обучающая выборка;
- 12% — валидационная выборка;
- 8% — тестовая выборка.

Для базовой CNN-модели использовалась другая схема разделения:

- 80% — обучающая выборка;
- 10% — валидационная выборка;
- 10% — тестовая выборка.

Следует отметить, что набор данных является несбалансированным. Количество изображений с пневмонией примерно в 2,7 раза превышает количество нормальных снимков. Для уменьшения влияния дисбаланса при формировании пользовательских выборок использовалось стратифицированное разделение данных, благодаря которому сохранялось одинаковое соотношение классов в обучающей, валидационной и тестовой выборках.

Для предотвращения утечки данных между выборками использовалось фиксированное значение параметра random_state, а также стратифицированное разделение изображений. Это позволило исключить случайное изменение распределения классов и обеспечить корректность проведения экспериментов.

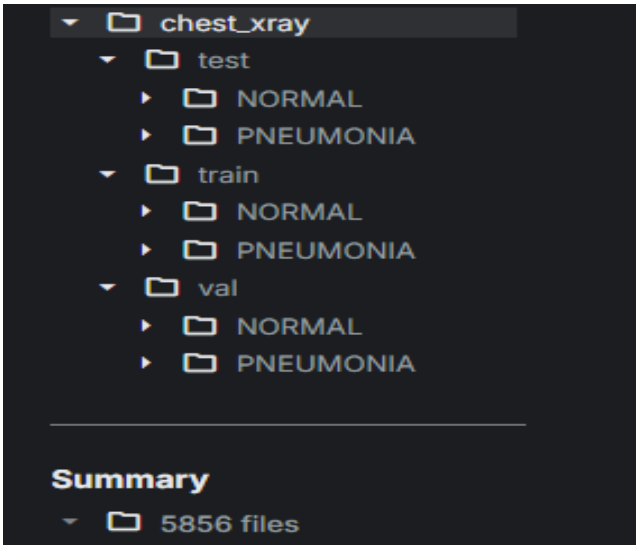


Рисунок 2 — Структура набора данных Chest X-Ray Pneumonia Dataset

2.2. Предварительная обработка изображений

Перед обучением моделей выполнялась предварительная обработка рентгеновских изображений с использованием TensorFlow Keras [15, 16] и OpenCV [17].

Для моделей DenseNet121, EfficientNetB0, ResNet50 и MobileNetV2 изображения приводились к размеру 224×224 пикселя, что соответствует входным требованиям предобученных моделей ImageNet.

В базовой CNN-модели использовались изображения в формате grayscale. Для моделей transfer learning изображения преобразовывались в RGB-формат, поскольку данные архитектуры рассчитаны на трёхканальные входные данные.

Для моделей DenseNet121 и EfficientNetB0 дополнительно использовалось преобразование:

cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

Изменение размера изображений выполнялось автоматически средствами TensorFlow Keras при загрузке данных через image_dataset_from_directory и ImageDataGenerator.

После изменения размера выполнялась нормализация значений пикселей:

image = image / 255.0

В результате значения пикселей приводились к диапазону от 0 до 1.

Дополнительная нормализация mean/std ImageNet в рамках работы не использовалась. Это позволило сохранить единый подход к предварительной обработке данных для всех исследуемых архитектур.

После завершения обработки изображения преобразовывались в массивы NumPy [18] и передавались в модели TensorFlow Keras.

2.3. Аугментация данных

Для уменьшения вероятности переобучения использовалась аугментация изображений, применяемая только к обучающей выборке.

В зависимости от используемой архитектуры выполнялись следующие преобразования:

- случайный поворот изображения;
- масштабирование;
- смещение по ширине и высоте;
- горизонтальное отражение.

Для большинства моделей использовались небольшие значения параметров аугментации: rotation_range ≈ 10–15 и zoom_range ≈ 0.1. Такие преобразования позволяют повысить устойчивость модели к небольшим изменениям положения пациента во время рентгенографии.

Параметры width_shift_range и height_shift_range использовались для повышения устойчивости к смещению области грудной клетки внутри изображения.

Вертикальное отражение (vertical_flip) не применялось, поскольку приводит к анатомически некорректным изображениям.

Горизонтальное отражение (horizontal_flip) использовалось ограниченно для увеличения разнообразия обучающих данных. Поскольку целью работы являлось обнаружение признаков пневмонии, а не определение её точной локализации относительно левого или правого лёгкого, данное преобразование было признано допустимым.

Аугментация использовалась только во время обучения и не применялась к тестовой выборке, что обеспечивало объективность итоговой оценки качества моделей.

2.4. Обучение моделей

Обучение моделей выполнялось с использованием метода обратного распространения ошибки (backpropagation) [2]. В процессе обучения модели получали изображения из обучающей выборки, формировали предсказания и корректировали свои параметры для уменьшения значения функции потерь.

В зависимости от архитектуры использовались различные функции потерь. Для моделей DenseNet121, EfficientNetB0 и базовой CNN-модели использовалась функция categorical cross-entropy. Такой выбор связан с тем, что данные модели формировали вероятности для двух выходных категорий. В моделях ResNet50 и MobileNetV2 применялась функция binary cross-entropy, поскольку результат определялся одним выходным значением.

Оптимизация параметров всех моделей выполнялась с использованием алгоритма Adam [19], который широко применяется в задачах глубокого обучения благодаря стабильности обучения и высокой скорости сходимости.

Обучение проводилось в течение нескольких эпох.После каждой эпохи оценивались результаты модели на обучающей и валидационной выборках. Это позволяло отслеживать динамику обучения и своевременно выявлять признаки переобучения модели.

В процессе обучения использовались EarlyStopping и ModelCheckpoint. Это позволяло сохранять лучший результат и избегать избыточного обучения модели и автоматически завершать обучение при отсутствии улучшения результатов на валидационной выборке.

2.5. Модель DenseNet121

Для решения задачи классификации рентгеновских изображений использовалась архитектура DenseNet121 из библиотеки TensorFlow Keras [20]. В качестве начальных параметров применялись предобученные веса

ImageNet, что позволило использовать подход transfer learning и сократить время обучения модели.

Базовая часть сети подключалась без верхнего классификационного блока (include_top=False). На первом этапе параметры основной части сети не изменялись. Обучение проводилось только для новых слоёв, добавленных поверх базовой архитектуры.

После базовой части DenseNet121 были добавлены следующие слои:

- GlobalAveragePooling2D;
- BatchNormalization;
- Dropout(0.5);
- Dense(num_classes, activation='softmax').

Для обучения использовалась функция потерь categorical_crossentropy, а оптимизация параметров выполнялась алгоритмом Adam с коэффициентом обучения learning_rate = 0.001.

Основные параметры обучения:

- размер входного изображения — 224×224 пикселя;
- размер пакета (batch_size) — 16;
- максимальное число эпох — 20;
- EarlyStopping (patience = 5);
- ModelCheckpoint для сохранения лучшей версии модели.

Для проверки работы модели использовалась тестовая выборка, не участвовавшая в обучении. Качество классификации оценивалось с помощью метрик Accuracy, Precision, Recall и F1-score. Также была построена матрица ошибок (Confusion Matrix), представленная на рисунке 3.

Матрица ошибок позволила отдельно оценить количество корректных классификаций, а также случаи ложноположительных и ложноотрицательных результатов. Для медицинской задачи особенно важны ложноотрицательные случаи, когда снимок с признаками пневмонии ошибочно относится к классу

NORMAL, поскольку такая ошибка может привести к недооценке состояния пациента.

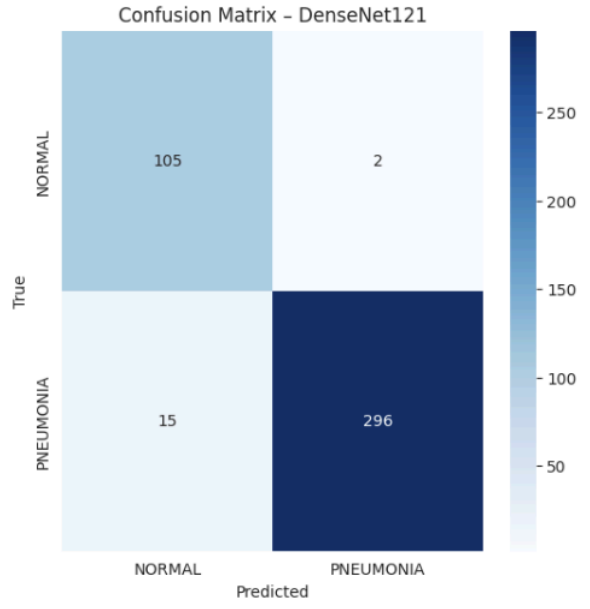


Рисунок 3 — Confusion Matrix DenseNet121

После сравнения всех обученных моделей для дальнейшей работы была выбрана DenseNet121. По этой причине данная модель была выбрана в качестве основной модели разработанной системы и впоследствии экспортирована в формат ONNX для интеграции в серверную часть приложения.

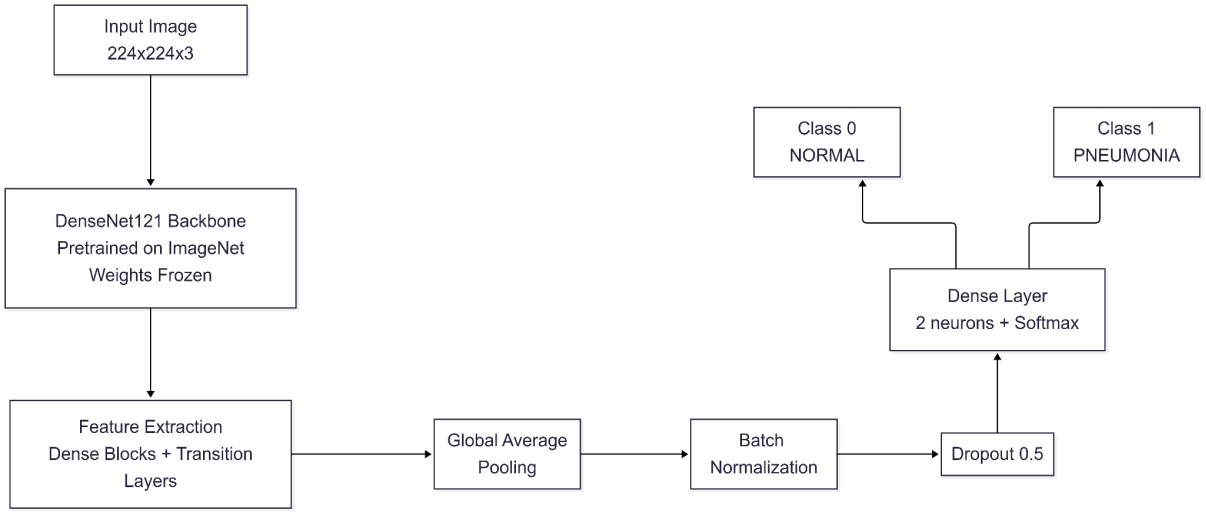


Рисунок 4 — Архитектура модели DenseNet121

На рисунке 5 представлены примеры ложноотрицательных классификаций. Анализ таких случаев показал, что ошибочно классифицированные изображения, как правило, содержат слабо выраженные признаки пневмонии или небольшие области поражения лёгочной ткани, что затрудняет их обнаружение моделью.

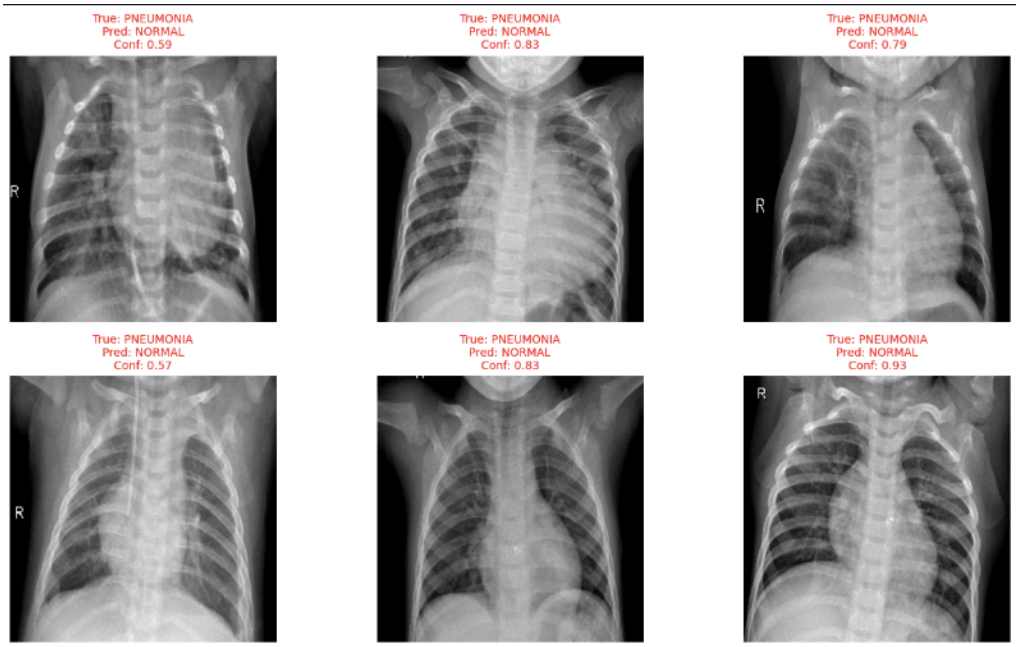


Рисунок 5 — Примеры ложноотрицательных результатов

2.6. Модель EfficientNetB0

В рамках исследования также была рассмотрена архитектура EfficientNetB0 [21]. Данная модель была включена в эксперимент для сравнения её качества с другими архитектурами глубокого обучения, используемыми при классификации рентгеновских изображений.

Архитектура модели включала последовательность MBConv-блоков с механизмом squeeze-and-excitation, обеспечивающим более эффективное использование признаков изображения. После сверточной части использовались слои:

- GlobalAveragePooling2D;
- Dropout(0.3);

- выходной слой Dense с функцией активации Softmax.

Для обучения применялась функция потерь categorical_crossentropy, а оптимизация параметров выполнялась алгоритмом Adam с коэффициентом обучения learning_rate = 0.001.

Основные параметры обучения:

- размер входного изображения — 224×224 пикселя;
- максимальное число эпох — 20;
- EarlyStopping (patience = 5);
- ModelCheckpoint для сохранения модели с лучшими показателями на этапе обучения.

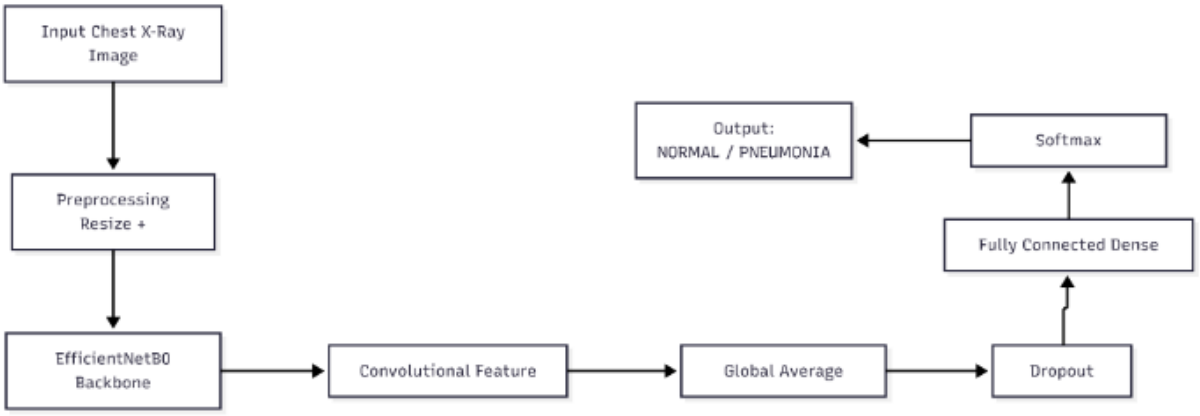


Рисунок 6 — Архитектура модели EfficientNetB0

2.7. Модель ResNet50

В рамках исследования также использовалась архитектура ResNet50 из библиотеки TensorFlow Keras [22]. Для обучения применялась предобученная версия модели с весами ImageNet (weights='imagenet').

Базовая часть ResNet50 использовалась без верхнего классификационного блока (include_top=False). После сверточной части модели были добавлены дополнительные слои:

- GlobalAveragePooling2D();
- BatchNormalization();
- Dropout(0.5);

- Выходной слой Dense(1, activation='sigmoid').

Для классификации использовалась бинарная схема с одной выходной вероятностью. В качестве функции потерь применялась binary_crossentropy.

На начальном этапе обучения базовая сверточная часть модели была заморожена (base_model.trainable = False). После этого обучались только добавленные слои.

Дополнительно применялись callbacks EarlyStopping(patience = 5) и ModelCheckpoint во время обучения для контроля переобучения и сохранения лучшей версии модели.

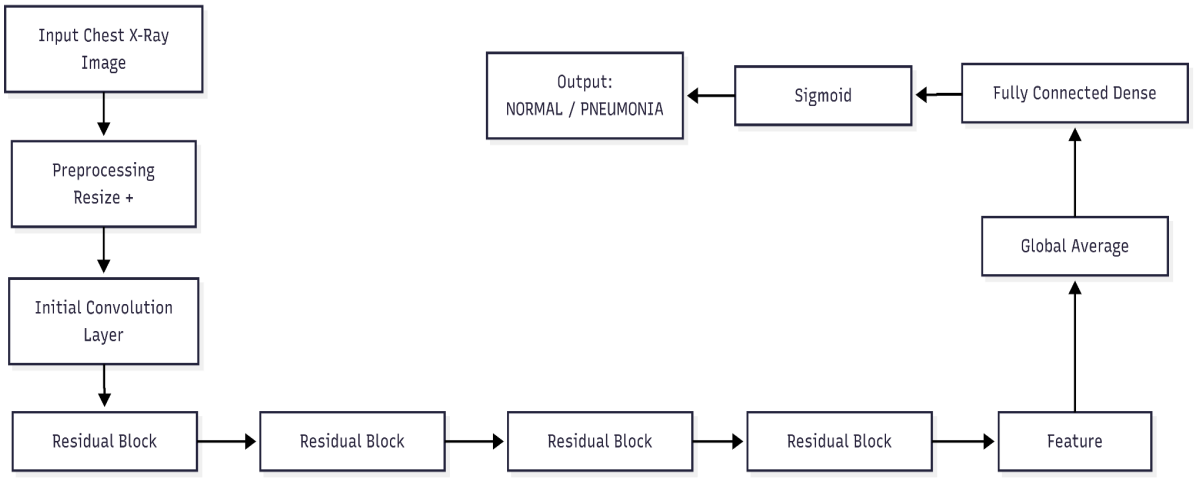


Рисунок 7 — Архитектура модели ResNet50

2.8. Модель MobileNetV2

В рамках исследования архитектура MobileNetV2 рассматривалась как облегчённая альтернатива более крупным моделям глубокого обучения [23]. Основным преимуществом данной архитектуры являются низкие вычислительные затраты при сохранении приемлемого качества классификации.

Для экспериментов использовалась версия модели с предобученными весами ImageNet. Базовая часть сети подключалась без верхнего классификационного блока, после чего были добавлены следующие слои:

- GlobalAveragePooling2D;

- BatchNormalization;
- Dropout(0.3);
- Dense(1, activation='sigmoid').

Для обучения использовалась функция потерь binary_crossentropy, соответствующая задаче бинарной классификации. На начальном этапе основная часть модели оставалась без изменений, а обучение выполнялось только для добавленных классификационных слоёв.

Для контроля процесса обучения применялись механизмы EarlyStopping и ModelCheckpoint.

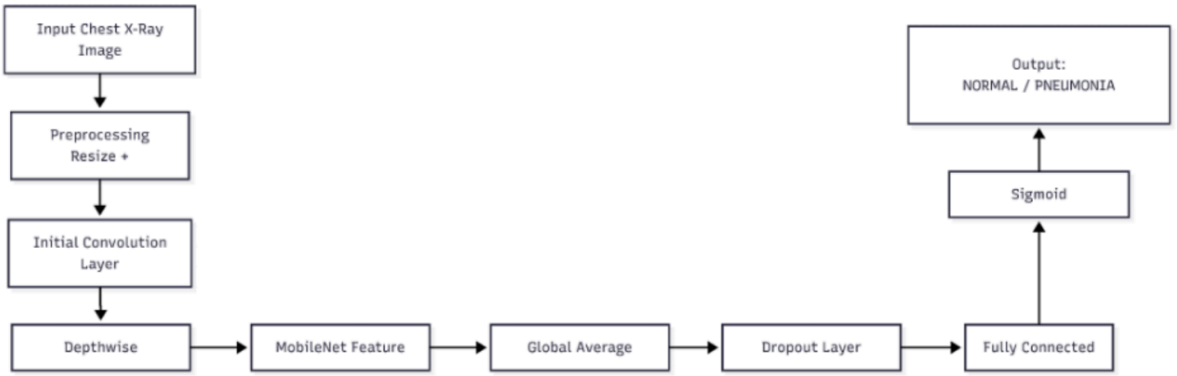


Рисунок 8 — Архитектура модели MobileNetV2

2.9. Базовая модель сверточной нейронной сети (CNN)

На начальном этапе исследования была реализована собственная CNN-модель без использования предобученных весов. она использовалась как baseline-модель для сравнения с более сложными архитектурами transfer learning [3].

Модель была реализована с использованием Sequential API библиотеки TensorFlow Keras. В качестве входных данных использовались изображения размером 224×224 пикселя в grayscale-формате.

Архитектура модели включала четыре последовательных сверточных блока. Каждый блок состоял из двух слоёв Conv2D с функцией активации

ReLU и слоя MaxPooling2D для уменьшения размерности признакового пространства.

Количество фильтров постепенно увеличивалось:

- 32 фильтра в первом блоке;
- 64 фильтра во втором блоке;
- 128 фильтров в третьем блоке;
- 256 фильтров в четвёртом блоке.

Постепенное увеличение количества фильтров позволяло модели сначала извлекать простые признаки изображений, такие как контуры и границы объектов, а на более глубоких уровнях сети более сложные структуры рентгеновских изображений.

Использование MaxPooling2D уменьшало размерность признакового пространства и снижало вычислительную нагрузку во время обучения модели.

После сверточной части модели использовались слои:

- Flatten();
- Dropout(0.3);
- Dense(256, activation='relu');
- Dense(2, activation='softmax').

Слой Dropout(0.3) применялся для уменьшения вероятности переобучения модели.

Для классификации использовалась двухклассовая схема с функцией потерь categorical_crossentropy. Оптимизация параметров выполнялась алгоритмом Adam.

Общее количество параметров модели составило 7 726 050, при этом все параметры являлись обучаемыми (Trainable params: 7,726,050). Основная часть параметров приходилась на полносвязный слой Dense(256), содержащий 6 553 856 параметров.

В отличие от DenseNet121, ResNet50 и MobileNetV2, данная модель обучалась без transfer learning и без использования предобученных весов. Это позволило использовать её как базовый ориентир для оценки влияния предобученных архитектур на качество классификации рентгеновских изображений.

Несмотря на относительно простую архитектуру, модель показала работоспособность подхода к автоматической классификации рентгеновских изображений и использовалась как baseline-модель при сравнении результатов исследуемых архитектур.

Таблица 3 — Архитектура базовой CNN-модели

Layer (type)	**Parameters**	**Output Shape**	**Param count**
Conv2D	32 фильтра, 3×3, ReLU	(None, 222, 222, 32)	320
Conv2D	32 фильтра, 3×3, ReLU	(None, 220, 220, 32)	9248
MaxPooling2D	2×2	(None, 110, 110, 32)	0
Conv2D	64 фильтра, 3×3, ReLU	(None, 108, 108, 64)	18496
Conv2D	64 фильтра, 3×3, ReLU	(None, 106, 106, 64)	36928
MaxPooling2D	2×2	(None, 53, 53, 64)	0
Conv2D	128 фильтров, 3×3, ReLU	(None, 51, 51, 128)	73856
Conv2D	128 фильтров, 3×3, ReLU	(None, 49, 49, 128)	147584
MaxPooling2D	2×2	(None, 24, 24, 128)	0
Conv2D	256 фильтров, 3×3, ReLU	(None, 22, 22, 256)	295168
Conv2D	256 фильтров, 3×3, ReLU	(None, 20, 20, 256)	590080
MaxPooling2D	2×2	(None, 10, 10, 256)	0
Flatten	—	(None, 25600)	0
Dropout	0.3	(None, 25600)	0

Dense	256 нейронов, ReLU	(None, 256)	6553856
Dense	2 нейрона, Softmax	(None, 2)	514

Обучение модели выполнялось на GPU NVIDIA Tesla P100 с использованием TensorFlow Keras.

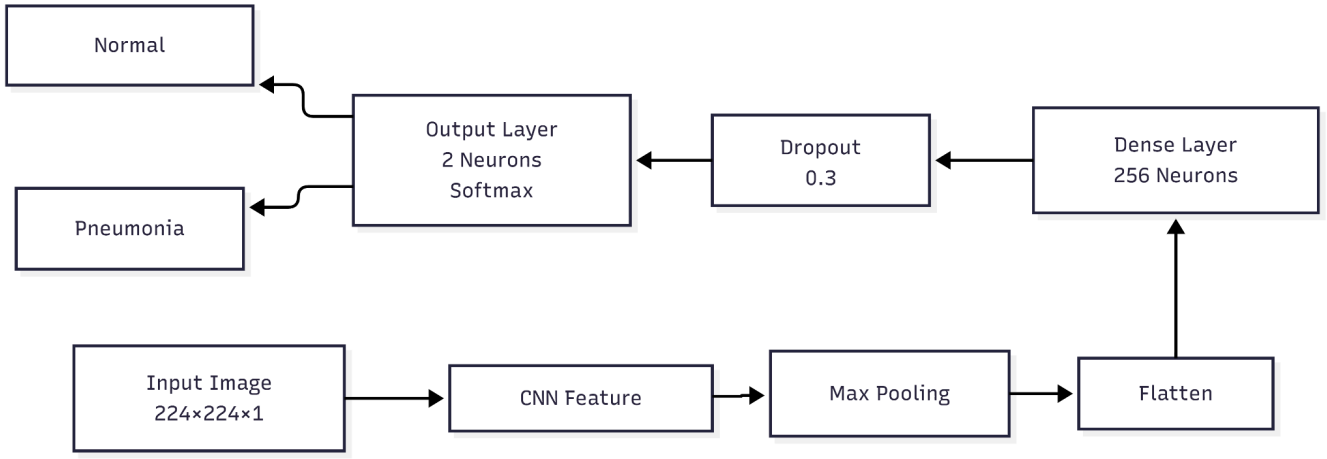


Рисунок 9 — Архитектура модели CNN

2.10. Оценка качества моделей

После завершения обучения все модели оценивались на тестовых выборках, не использовавшихся в процессе обучения. Для анализа качества классификации рассчитывались метрики Accuracy, Precision, Recall и F1-score.

Для задачи обнаружения пневмонии особое внимание уделялось метрике Recall, поскольку ложноотрицательные результаты являются критичными для медицинских систем диагностики. Ошибка классификации, при которой изображение с признаками пневмонии определяется как нормальное, потенциально представляет больший риск по сравнению с ложноположительной классификацией.

В таблице представлены метрики для класса Pneumonia, поскольку основная задача исследования связана с обнаружением признаков пневмонии на рентгеновских изображениях.

Таблица 4 — Сравнение результатов оценки качества моделей

Модель	Accuracy	Precision	Recall	F1-score
DenseNet121	0.96	0.96	0.95	0.97
EfficientNetB0	0.95	0.96	0.94	0.96
ResNet50	0.85	0.87	0.85	0.84
MobileNetV2	0.90	0.90	0.90	0.89
CNN Model	0.93	0.99	0.91	0.93

Наиболее высокие результаты показала модель DenseNet121. Архитектура продемонстрировала высокий баланс между точностью классификации и способностью обнаруживать изображения с признаками пневмонии.

При интерпретации результатов необходимо учитывать ограничения набора данных Chest X-Ray Pneumonia Dataset. Для уменьшения риска утечки данных использовалось исходное разделение выборок, предоставленное авторами набора данных, без дополнительного перемешивания изображений между обучающей и тестовой выборками.

ГЛАВА 3. РАЗРАБОТКА ПРОГРАММНОЙ СИСТЕМЫ АНАЛИЗА МЕДИЦИНСКИХ ИЗОБРАЖЕНИЙ

3.1. Общая архитектура системы

После обучения модели была разработана программная система для анализа рентгеновских изображений грудной клетки. Система предназначена для автоматического выявления признаков пневмонии, хранения результатов исследований и предоставления врачу дополнительной аналитической информации.

Архитектура системы построена по клиент-серверному принципу. Пользователь взаимодействует с системой через пользовательский интерфейс, где доступны все функции системы: загрузки изображений, работы с пациентами, просмотра истории исследований, статистики и консультаций между врачами.

К основным компонентам системы относятся:

- веб-интерфейс;
- backend API;
- модуль машинного обучения;
- база данных PostgreSQL [27];
- модуль генерации пояснительного текста;
- модуль построения тепловых карт;
- система хранения медицинских данных и результатов исследований.

После входа в систему пользователь загружает рентгеновское изображение. Затем изображение передается на сервер, где выполняется предварительная обработка данных и запуск модели машинного обучения в формате ONNX [24]. По результатам анализа система определяет наличие или отсутствие признаков пневмонии и формирует показатели уверенности модели.

Дополнительно выполняется генерация тепловой карты, позволяющей визуализировать области изображения, оказавшие наибольшее влияние на решение модели. Для построения тепловых карт используется DenseNet121 и метод Grad-CAM [33].

После завершения анализа результаты сохраняются в базе данных PostgreSQL. При необходимости система формирует пояснительный текст с использованием языковой модели Qwen [35], работающей локально через Ollama [34]. Такой подход позволяет исключить передачу медицинских данных во внешние облачные сервисы.

Кроме веб-версии система поддерживает работу в виде настольного приложения на базе ElectronJS [36].

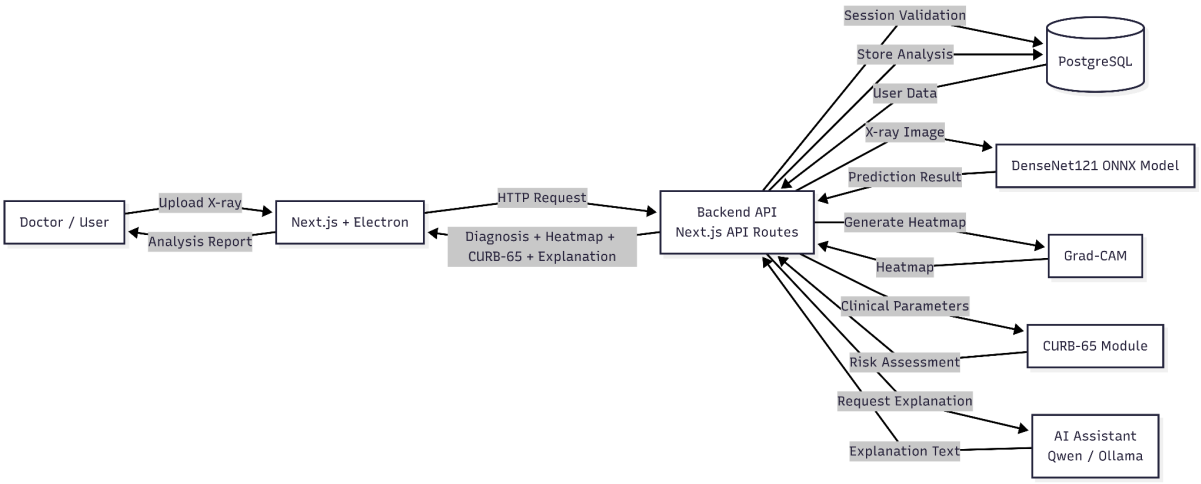


Рисунок 10 — Общая архитектура программной системы анализа медицинских изображений

3.2. Клиентская часть системы

3.2.1. Страница авторизации пользователей

Для обеспечения безопасного доступа к функциональным возможностям системы был реализован отдельный интерфейс авторизации пользователей. Страница авторизации является первой точкой взаимодействия пользователя с приложением и предназначена для проверки

учётных данных перед предоставлением доступа к медицинской информации и результатам анализа.

Интерфейс страницы содержит поля для ввода адреса электронной почты и пароля, а также кнопку подтверждения входа. После заполнения формы данные передаются на сервер посредством HTTP-запроса к API-маршруту **/api/login**.

После отправки формы система выполняет проверку корректности введённых данных. В случае отсутствия обязательных полей пользователю отображается соответствующее уведомление. При успешной передаче запроса сервер выполняет процедуру аутентификации пользователя и возвращает результат проверки.

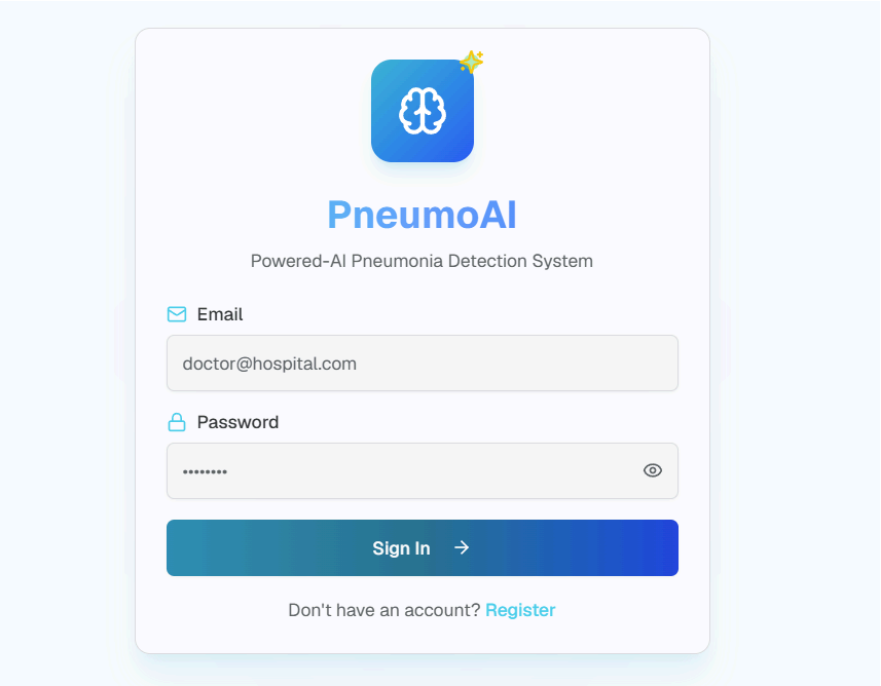


Рисунок 11 — Интерфейс авторизации пользователя

После успешного входа автоматически создаётся пользовательская сессия, позволяющая сохранить состояние авторизации между запросами. Пользователь получает доступ к основным разделам системы, включая загрузку медицинских изображений, просмотр результатов анализа, работу с пациентами и использование AI-инструментов.

Для повышения удобства работы реализован механизм автоматического перенаправления. Если пользователь уже имеет активную сессию, повторный переход на страницу авторизации приводит к автоматическому открытию главной страницы системы без необходимости повторного ввода учётных данных.

3.2.2. Страница регистрации пользователей

Для подключения новых специалистов к платформе был реализован отдельный интерфейс регистрации пользователей. Страница предназначена для создания учётной записи и последующего получения доступа к функциональным возможностям системы анализа медицинских изображений.

Форма регистрации содержит поля для ввода полного имени пользователя, адреса электронной почты и пароля. Дополнительно в системе предусмотрена поддержка ролевой модели, позволяющая назначать различные категории медицинского персонала. В текущей реализации основным типом пользователя является врач.

Перед отправкой данных выполняется клиентская проверка корректности введённой информации. Система контролирует заполнение обязательных полей, корректность формата электронной почты и минимальную длину пароля. Для повышения удобства работы реализован индикатор сложности пароля, который позволяет пользователю оценить надёжность выбранной комбинации ещё до завершения регистрации.

После успешного прохождения проверки данные передаются на сервер посредством HTTP-запроса к API-маршруту регистрации. Во время выполнения операции отображается состояние загрузки, информирующее пользователя о процессе создания учётной записи.

В случае успешной регистрации пользователь автоматически перенаправляется на главную страницу системы и получает доступ к основным функциональным модулям платформы. Если учётная запись с

указанным адресом электронной почты уже существует или возникла ошибка при создании пользователя, система отображает соответствующее уведомление.

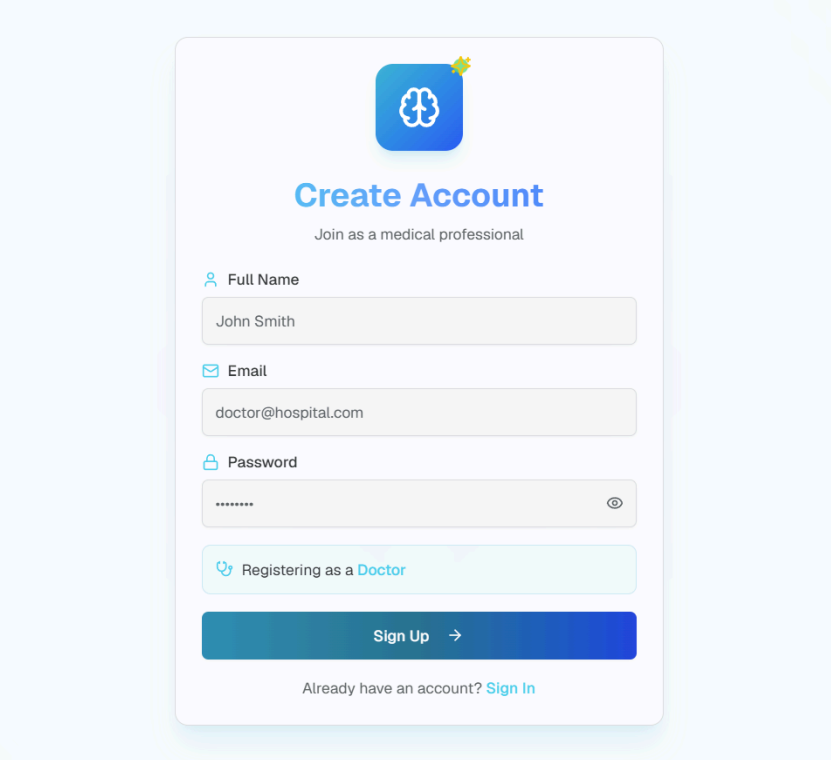


Рисунок 12 — Интерфейс регистрации пользователя

3.2.3. Главная страница системы

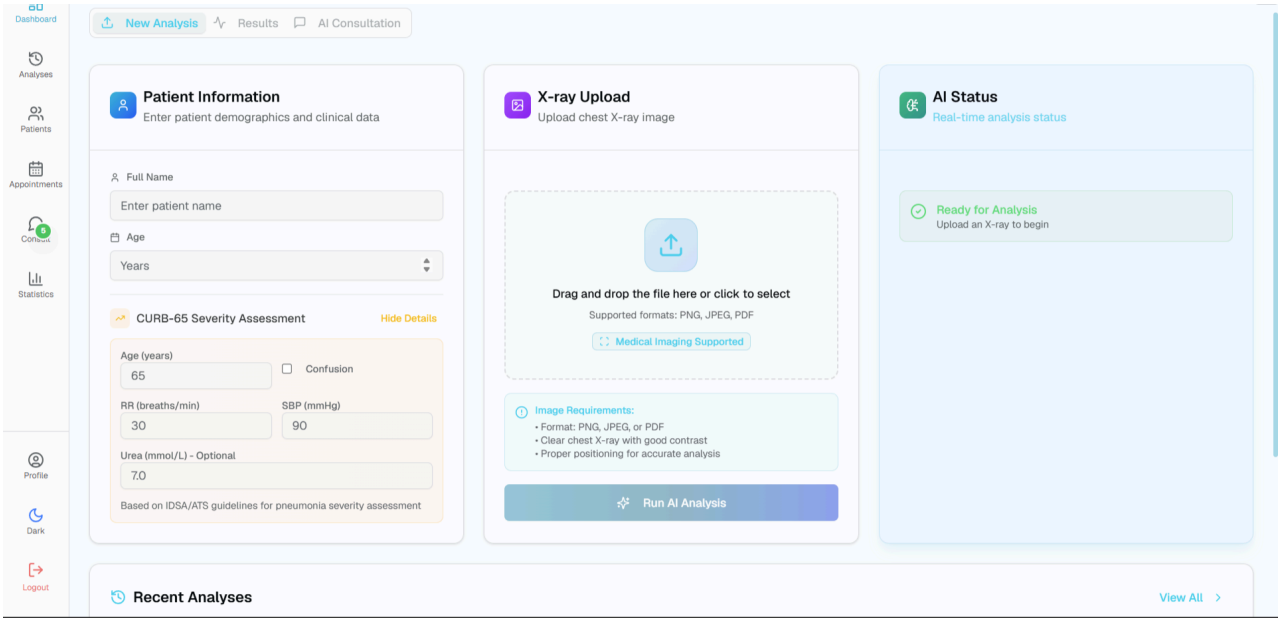
После успешной авторизации пользователь переходит на главную страницу системы. Основной сценарий работы реализован во вкладке New Analysis, которая предназначена для подготовки нового исследования. Внешний вид главной страницы представлен на рисунке 13.

Рабочая область содержит два основных функциональных блока. Первый блок предназначен для ввода информации о пациенте. Пользователь может указать имя пациента, возраст и дополнительные клинические параметры, используемые для расчёта шкалы CURB-65. Введённые данные используются совместно с результатами анализа рентгеновского изображения для оценки степени риска при выявлении пневмонии.

Второй блок предназначен для загрузки рентгеновского снимка грудной клетки. Пользователь может выбрать файл через стандартный диалог операционной системы либо воспользоваться механизмом Drag & Drop. После выбора изображения отображается его предварительный просмотр, что позволяет убедиться в корректности загружаемого исследования перед запуском анализа.

Как показано на рисунке 13, вкладка New Analysis объединяет этапы подготовки данных пациента и загрузки медицинского изображения в едином интерфейсе. После запуска анализа результаты исследования становятся доступны во вкладке Results, а дополнительные вопросы по результатам анализа могут быть рассмотрены во вкладке AI Consultation.

Рисунок 13 — Главная страница системы



3.2.4. Отображение результатов анализа

После завершения обработки изображения пользователь переходит к просмотру результатов исследования (рис. 14).

На странице отображается итоговый результат классификации изображения, определяющий наличие или отсутствие признаков пневмонии.

Для повышения удобства восприятия результат сопровождается уровнем уверенности модели, что позволяет оценить степень достоверности полученного предсказания.

При наличии клинических данных пациента дополнительно отображаются результаты оценки по шкале CURB-65. Пользователь может ознакомиться с итоговым баллом и соответствующей категорией риска без необходимости выполнения дополнительных расчётов.

Дополнительно пользователю доступны функции формирования PDF-отчёта и отправки исследования на повторное рассмотрение другому специалисту в рамках механизма второго мнения. Это позволяет использовать результаты анализа не только для первичной оценки исследования, но и для дальнейшей клинической работы с пациентом.

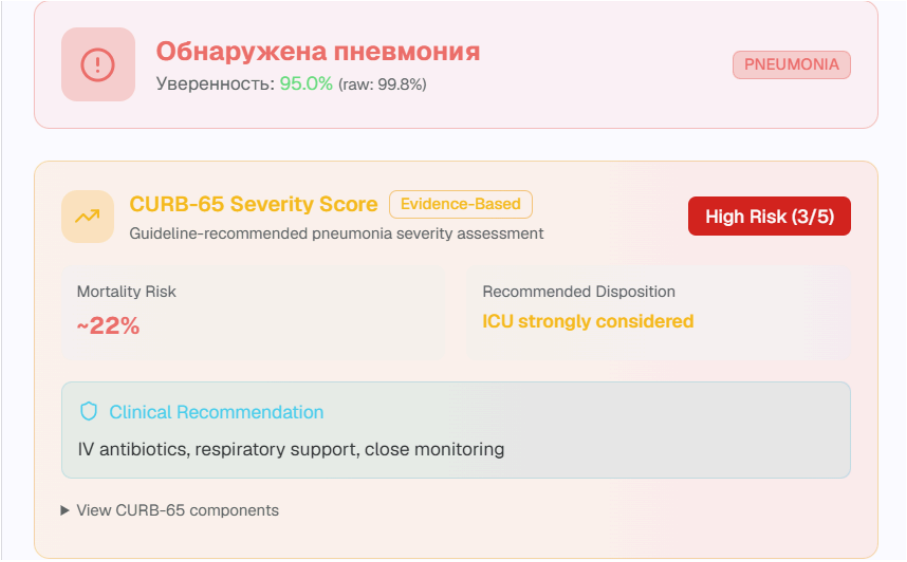


Рисунок 14 — Отображение результатов анализа

3.2.5. Формирование пояснительного текста и ИИ ассистента

После завершения анализа изображения система предоставляет пользователю два дополнительных инструмента для интерпретации полученных результатов: автоматическое формирование пояснительного текста и интеллектуальный консультант.

Пояснительный текст отображается вместе с результатами исследования и предназначен для представления результатов анализа в удобной для восприятия форме. Формируемая информация учитывает результат классификации изображения и дополнительные клинические данные пациента. Такой подход позволяет предоставить пользователю структурированное описание полученных результатов без необходимости самостоятельной интерпретации числовых показателей модели. Внешний вид модуля формирования пояснительного текста представлен в Приложении А.1.

Для получения дополнительной информации предусмотрен модуль консультации, реализованный в виде отдельной вкладки AI Consultation. Пользователь может задавать вопросы, связанные с результатами выполненного исследования, и получать пояснения в диалоговом режиме. Интерфейс консультации построен по принципу текстового чата и обеспечивает последовательное взаимодействие с системой.

Внешний вид ИИ-ассистента представлен в Приложении А.2. Пользователь может обращаться к системе с уточняющими вопросами по результатам исследования, не покидая рабочее пространство приложения.

3.2.6. Визуализация областей внимания модели

Для повышения интерпретируемости результатов анализа в системе предусмотрено построение тепловой карты (heatmap), отображающей области изображения, оказавшие наибольшее влияние на решение модели.

После завершения анализа пользователь может запустить генерацию тепловой карты непосредственно из интерфейса системы. Полученное изображение отображается поверх исходного рентгеновского снимка, что позволяет визуально оценить участки, на которые модель обращала внимание при формировании результата (рис. 15)

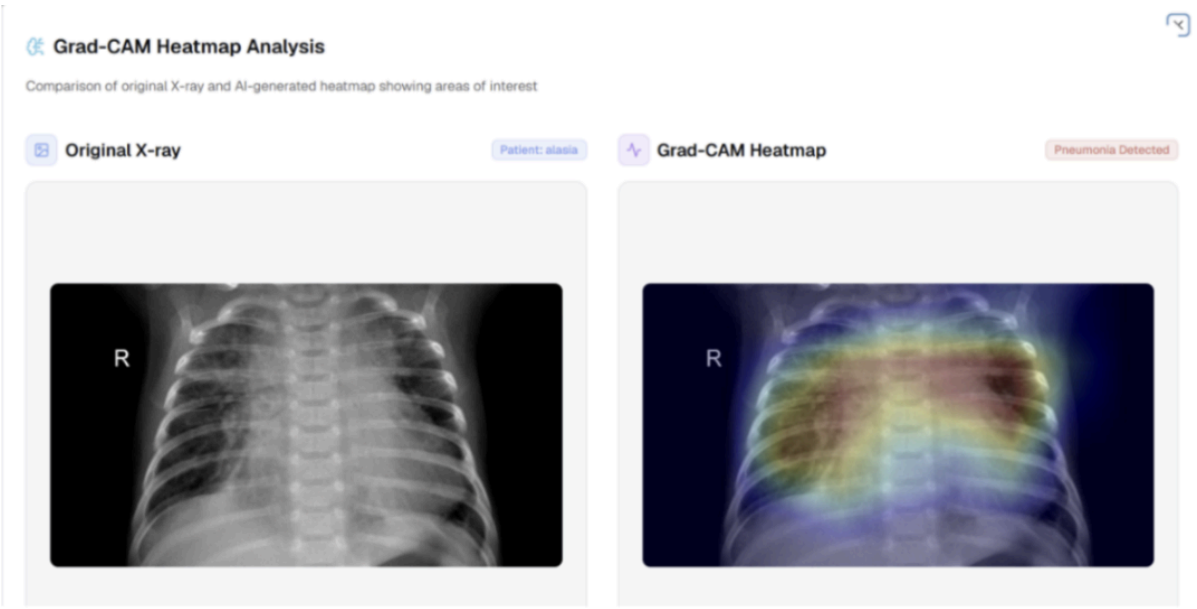


Рисунок 15 — тепловая карта

3.2.7. Страница регистрации пациента

На рисунке 16 представлена страница регистрации нового пациента. Данная страница предназначена для создания персональной карточки пациента и последующего хранения результатов проведённых исследований.

В центральной части страницы расположена форма ввода данных, содержащая основные сведения о пациенте: имя, возраст, пол и контактный номер телефона. Дополнительно пользователь может указать информацию о медицинском анамнезе, включая хронические заболевания, аллергические реакции и ранее перенесённые операции, а также добавить служебные заметки.

Поле имени пациента является обязательным для заполнения. После ввода необходимых данных пользователь может сохранить информацию с помощью кнопки Create Patient. После успешного создания записи система автоматически открывает карточку зарегистрированного пациента для дальнейшей работы.

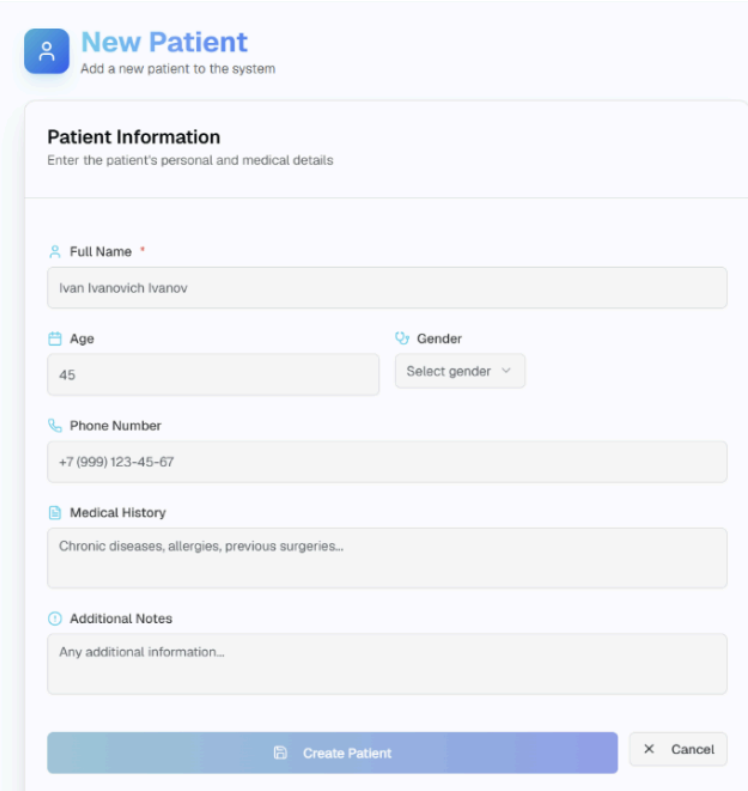


Рисунок 16 — страницы регистрации пациента

3.2.8. Страница управления пациентами

На рисунке, представленном в Приложении А.3, показана страница управления пациентами. Данная страница предназначена для просмотра и поиска ранее зарегистрированных пациентов.

В верхней части страницы расположено поле поиска, позволяющее выполнять фильтрацию записей по имени пациента. Ниже отображается список карточек пациентов, содержащих основную информацию, включая имя, возраст, пол, контактный номер телефона и дату добавления записи.

При выборе карточки пациента пользователь переходит к его персональной карточке для просмотра подробной информации и истории исследований.

3.2.9. Карточка пациента

На рисунке 17 представлена карточка пациента. Данная страница предназначена для централизованного хранения и просмотра информации о пациенте, а также связанных с ним результатов медицинских исследований.

В карточке отображаются основные персональные данные пациента, включая имя, возраст, пол и контактную информацию. Дополнительно пользователю доступны сведения медицинского анамнеза и служебные заметки, сохранённые при регистрации пациента.

Одним из ключевых элементов страницы является история проведённых исследований. Пользователь может просматривать ранее выполненные анализы, получать доступ к их результатам и использовать накопленные данные для дальнейшего наблюдения за состоянием пациента.

Кроме того, из карточки пациента осуществляется переход к созданию медицинских записей, содержащих результаты обследований, лабораторные показатели и клинические наблюдения. Интерфейс создания медицинской записи представлен в Приложении А.4.

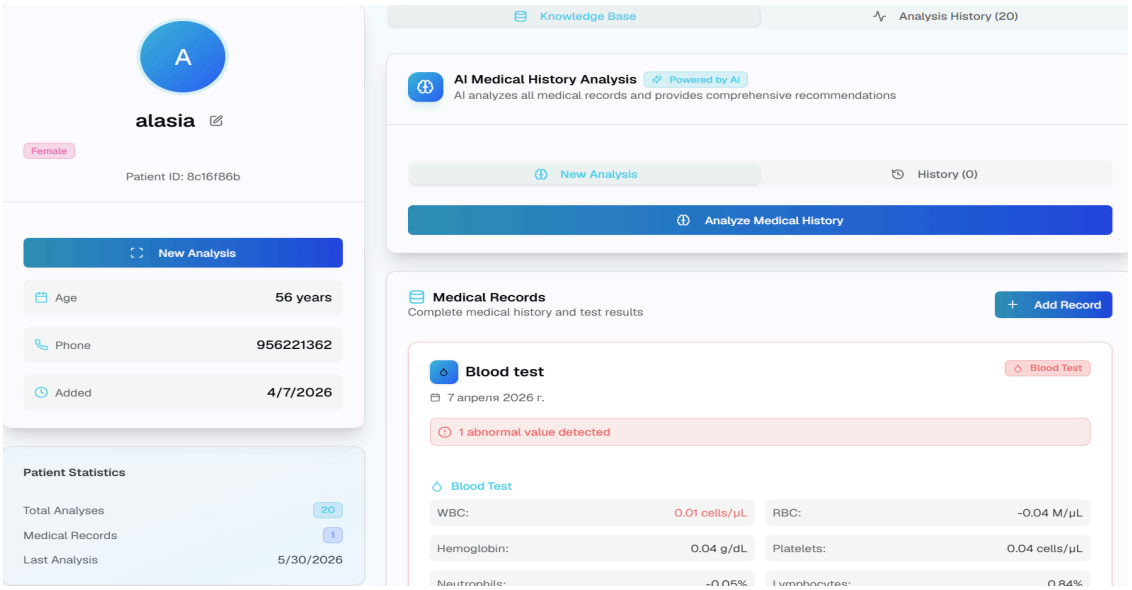


Рисунок 17 — Карточка пациента

3.2.10. Страница истории исследований

На рисунке 18 представлена страница истории исследований. Данный раздел предназначен для хранения и просмотра результатов ранее выполненных анализов рентгеновских изображений.

При открытии страницы клиентская часть приложения отправляет запрос к маршруту /api/history, после чего сервер возвращает список исследований, связанных с текущим пользователем. Полученные данные сохраняются в состоянии компонента и используются для динамического формирования списка записей без перезагрузки страницы.

Для отображения результатов используются карточки исследований, содержащие основные сведения о пациенте, результат классификации, уровень уверенности модели и дату проведения анализа. Записи отображаются в обратном хронологическом порядке, что позволяет быстро получать доступ к наиболее актуальным исследованиям.

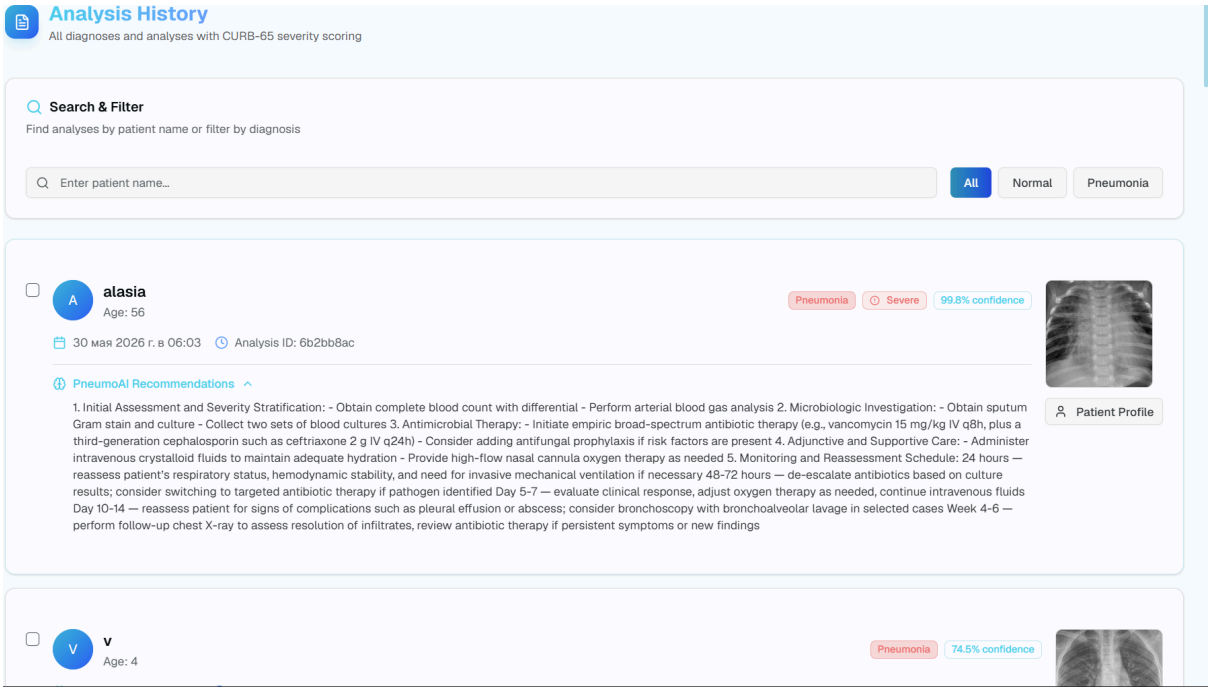


Рисунок 18 — История исследований

3.2.11. Страница последующего наблюдения пациента

Для контроля состояния пациента после проведённого исследования в системе реализован модуль последующего наблюдения. Данный раздел позволяет врачу планировать повторные приёмы и контролировать выполнение назначенных консультаций.

При открытии страницы выполняется запрос к серверу для получения списка ранее созданных записей наблюдения. Полученные данные отображаются в виде списка с разделением на предстоящие и завершённые визиты. Для каждой записи отображаются сведения о пациенте, дата и время приёма, а также текущий статус наблюдения.

Создание новой записи осуществляется через отдельную форму, в которой пользователь выбирает пациента, указывает дату и время повторного визита, а также при необходимости добавляет дополнительные комментарии. После сохранения информация передаётся на сервер и становится доступной в общем списке наблюдений.

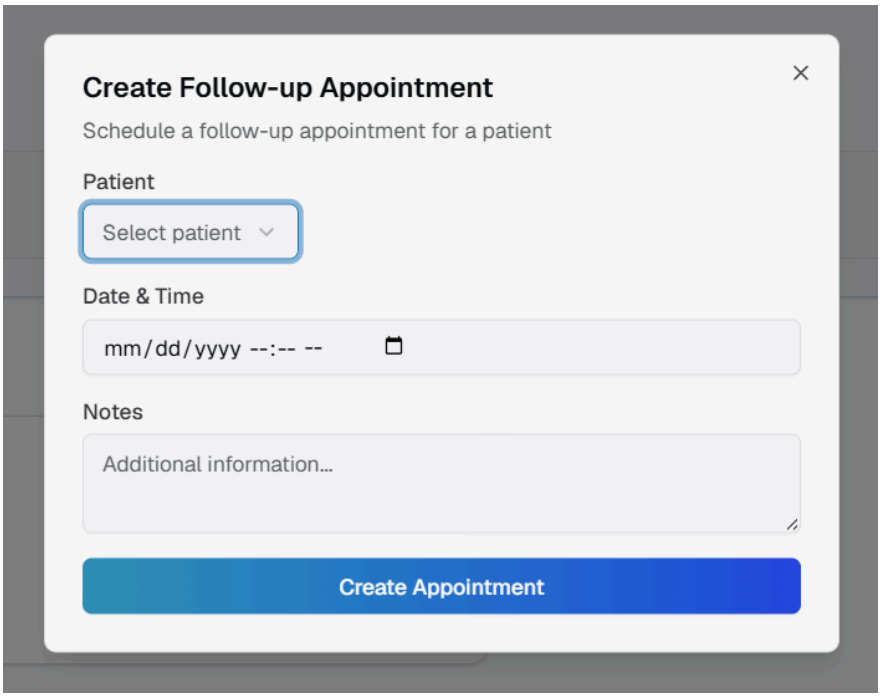


Рисунок 19 — Форма создания записи последующего наблюдения

Для удобства работы предусмотрены механизмы фильтрации и поиска записей, позволяющие быстро находить необходимые данные среди сохранённых наблюдений.

Интерфейс страницы последующего наблюдения представлен в Приложении А.5.

3.2.12. Страница консультаций

На рисунке 20 представлена страница консультаций, предназначенная для организации взаимодействия между врачами при анализе результатов исследований.

После завершения анализа рентгеновского изображения врач может отправить запрос на консультацию другому специалисту. Для этого в карточке результата исследования предусмотрена кнопка Consultation, открывающая форму создания запроса. Пользователь выбирает врача-консультанта и при необходимости добавляет комментарий с дополнительными вопросами или замечаниями по исследованию.

После отправки формы выполняется запрос к маршруту /api/second-opinions, который сохраняет информацию о консультации в базе данных и присваивает ей статус pending. Созданный запрос отображается в общем списке консультаций.

Страница консультаций предоставляет возможность просматривать отправленные и полученные запросы, отслеживать их текущий статус, а также получать доступ к информации об исследовании пациента. Для загрузки данных используется маршрут GET **/api/second-opinions**, который возвращает список консультаций, связанных с текущим пользователем.

Каждая запись содержит сведения о пациенте, результатах анализа, уровне уверенности модели и текущем состоянии запроса. Для удобства работы консультации разделяются по статусам, что позволяет быстро находить ожидающие рассмотрения, активные и завершённые запросы.

Для детального рассмотрения консультации используется отдельная страница проверки заключения, на которой врач-консультант может изучить результаты исследования и сформировать собственное экспертное мнение. Внешний вид данной страницы приведён в Приложении А.6.

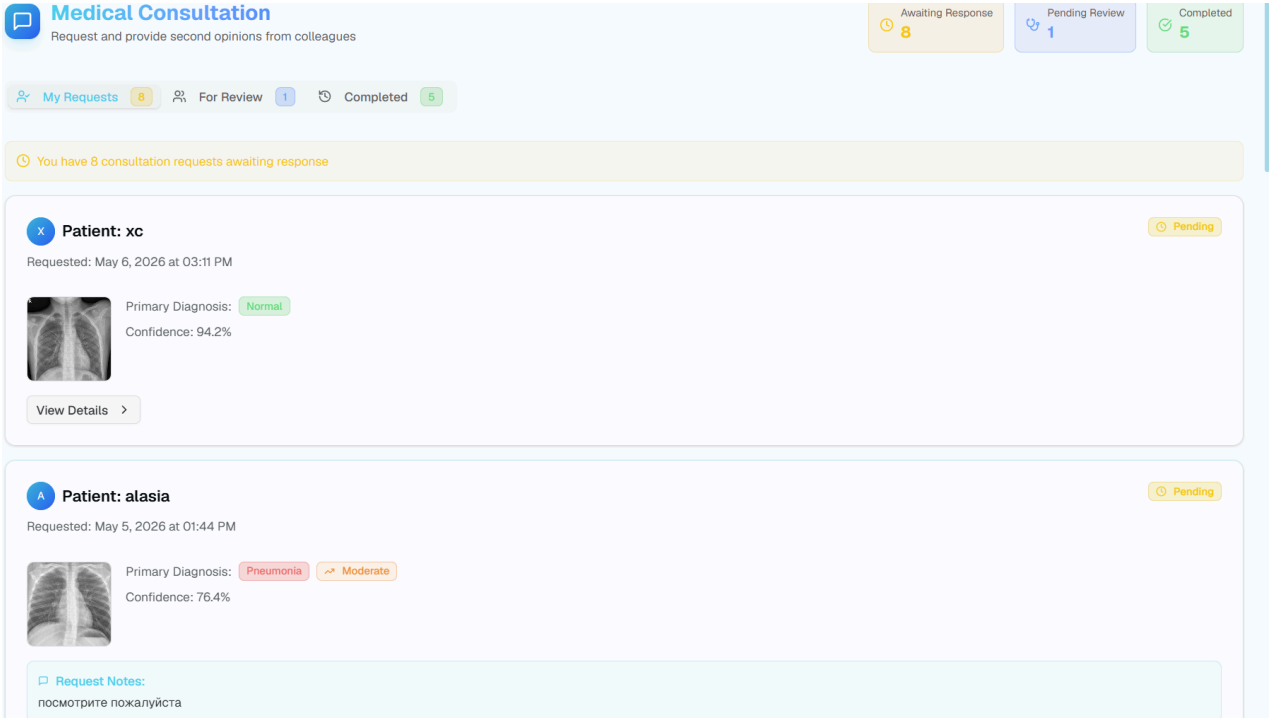


Рисунок 20 — Страница консультаций.

3.2.13. Страница статистики и аналитики

На рисунке 21 представлена страница статистики и аналитики. Данная страница предназначена для визуального представления накопленных диагностических данных и мониторинга работы системы.

Основные возможности страницы включают:

1. Отображение общей статистики системы, включая количество зарегистрированных пациентов, число выполненных исследований и количество выявленных случаев пневмонии.
2. Анализ динамики исследований во времени, позволяющий отслеживать изменение количества диагностических случаев за выбранный период.

3. Мониторинг распределения заболеваний по степени тяжести, что позволяет оценивать соотношение лёгких, среднетяжёлых и тяжёлых случаев пневмонии.
4. Сравнение результатов диагностики, включая соотношение нормальных исследований и случаев выявления пневмонии.
5. Визуализация данных с использованием интерактивных графиков и диаграмм, обеспечивающих более удобный анализ накопленной информации.
6. Фильтрация статистических данных по временным интервалам, позволяющая получать информацию за последние 7, 30 или 90 дней без перезагрузки страницы.

Для получения статистических данных клиентская часть взаимодействует с маршрутом /api/statistics, который выполняет сбор и агрегацию информации из базы данных. Полученные данные используются для построения графиков и диаграмм в режиме реального времени.

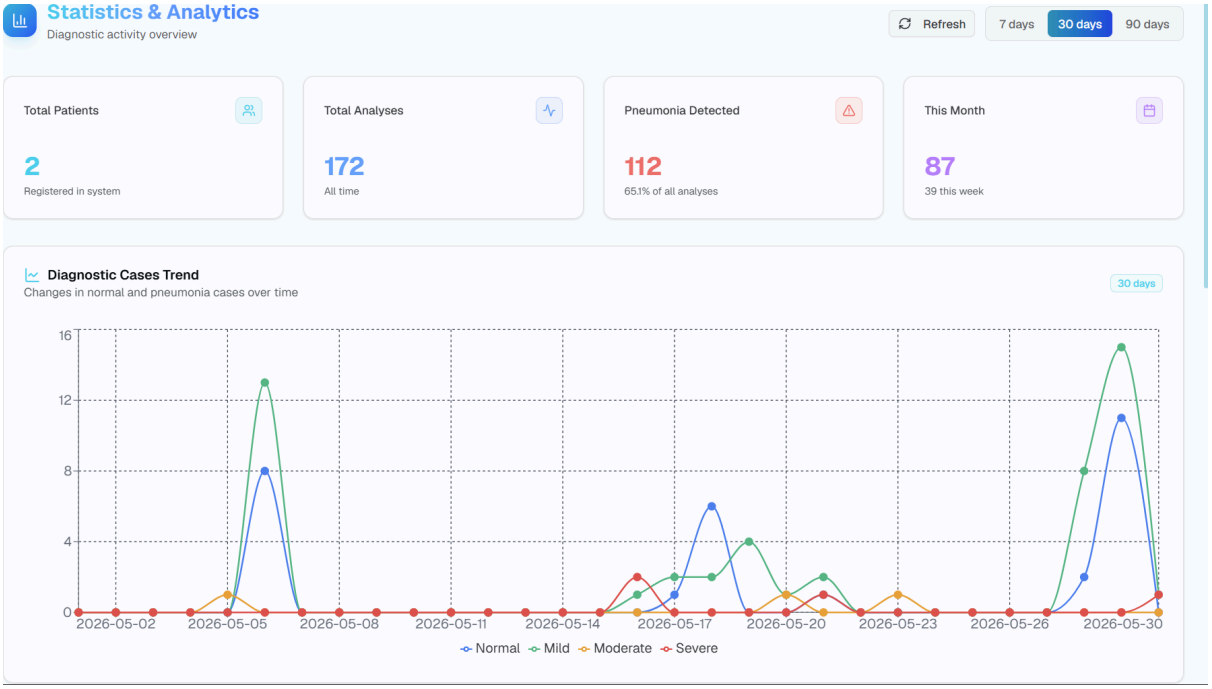


Рисунок 21 — Страница статистики

3.2.14. Страница профиля пользователя

Страница профиля пользователя предназначена для просмотра и управления персональными данными учётной записи медицинского специалиста.

Основные возможности страницы включают:

1. Просмотр информации об учётной записи, включая роль пользователя в системе и дату регистрации.
2. Отображение персональных данных пользователя, таких как имя и адрес электронной почты.
3. Редактирование личной информации, что позволяет пользователю актуализировать сведения без обращения к администратору системы.
4. Изменение пароля учётной записи, обеспечивающее дополнительный уровень защиты персональных данных и доступа к системе.
5. Проверка корректности вводимых данных, включая контроль совпадения нового пароля и подтверждения пароля перед сохранением изменений.
6. Отображение уведомлений о результате выполненных операций, позволяющее пользователю получать информацию об успешном сохранении данных или возникших ошибках.
7. Обеспечение безопасного доступа к информации профиля посредством проверки активной пользовательской сессии и механизма аутентификации.

Для получения информации о пользователе клиентская часть взаимодействует с маршрутом /api/auth/me, который выполняет проверку действительности пользовательской сессии и возвращает основные сведения об авторизованном пользователе. При этом конфиденциальные данные, включая хэш пароля, не передаются клиентской части и остаются недоступными для просмотра (Приложение А.7).

3.3. Серверная часть приложения

3.3.1. Система аутентификации и авторизации

Для ограничения доступа к медицинским данным и функциональным возможностям платформы в системе реализован механизм аутентификации и авторизации пользователей.

Процесс аутентификации начинается после получения POST-запроса на маршрут **/api/login**. Сервер извлекает адрес электронной почты и пароль пользователя, после чего выполняет поиск соответствующей записи в базе данных PostgreSQL [27]. Для хранения паролей используется механизм хэширования на основе алгоритма **SHA-256** [29] с дополнительной солью (salt), что позволяет исключить хранение паролей в открытом виде.

При выполнении входа введённый пользователем пароль повторно преобразуется в хэш и сравнивается со значением, сохранённым в базе данных. Если данные совпадают, пользователь считается успешно аутентифицированным.

После успешной проверки создаётся новая пользовательская сессия. Для её идентификации генерируется уникальный идентификатор, который сохраняется в таблице sessions базы данных PostgreSQL. Далее идентификатор передаётся клиентской части посредством HTTP-only cookie session_id [30]. Использование данного механизма позволяет ограничить доступ к данным сессии и повысить безопасность работы приложения.

Помимо процедуры входа в систему серверная часть поддерживает регистрацию новых пользователей через API-маршрут **/api/register**. После получения запроса выполняется проверка обязательных параметров, включая адрес электронной почты, пароль, полное имя пользователя и выбранную роль. Дополнительно контролируется корректность роли и отсутствие пользователя с указанным адресом электронной почты в базе данных.

После успешного прохождения проверок создаётся новая учётная запись пользователя. Пароль сохраняется в виде хэшированного значения, после чего автоматически создаётся пользовательская сессия. Благодаря этому пользователь может сразу приступить к работе с системой без повторного выполнения процедуры авторизации.

Использование серверных сессий, защищённых cookie и механизма хэширования паролей позволило реализовать централизованное управление доступом и обеспечить безопасную работу с медицинскими данными внутри платформы.

3.3.2. Модуль анализа медицинских изображений

Модуль анализа медицинских изображений реализован посредством API-маршрута **/api/analyze**. Данный маршрут является центральным компонентом системы и отвечает за получение изображения, запуск модели машинного обучения, расчёт дополнительных клинических показателей и сохранение результатов исследования.

После получения POST-запроса сервер извлекает идентификатор пользовательской сессии из cookie **session_id**. Далее посредством функции **getUserBySession()** выполняется проверка существования активной сессии. Если пользователь не авторизован, запрос завершается с кодом ответа 401.

Загружаемое изображение передаётся в составе объекта FormData. Помимо файла система принимает дополнительные параметры пациента, включая имя, возраст и клинические данные для последующего расчёта шкалы CURB-65.

На этапе валидации используется функция **validateUploadedFile()**, которая выполняет проверку MIME-типа, расширения файла и его размера. В текущей версии поддерживаются форматы JPEG, PNG и PDF. Максимальный размер файла ограничен 10 МБ. При нарушении указанных требований обработка прекращается до запуска модели.

После проверки выполняется нормализация входных данных посредством функции **normalizeInputFile()**. Для документов PDF используется функция **convertPdfToImage()**, преобразующая первую страницу документа в изображение. Далее функция **processImageForInference()** формирует две версии изображения: первую для передачи в модель машинного обучения и вторую для отображения в пользовательском интерфейсе. Для отображения используется библиотека Sharp [26], позволяющая автоматически выполнять изменение размера изображения и JPEG-сжатие.

Запуск модели осуществляется через функцию **runInference()**. В качестве модели используется DenseNet121, предварительно экспортированная в формат ONNX [24]. Для выполнения инференса применяется библиотека ONNX Runtime [25]. После обработки изображения система получает итоговый класс, вероятности принадлежности к каждому классу и уровень уверенности модели. В рамках текущей реализации поддерживаются два класса: NORMAL и PNEUMONIA.

Если результат анализа соответствует классу PNEUMONIA и пользователь указал клинические данные пациента, выполняется вызов функции **calculateCURB65()**. На основании введённых параметров рассчитывается итоговый балл CURB-65, категория риска и рекомендуемый уровень медицинского наблюдения.

После завершения анализа создаётся запись исследования посредством функции **createAnalysis()**. В базе данных сохраняются результат классификации, вероятность предсказания, данные пациента, параметры CURB-65 и дополнительная служебная информация. Параллельно выполняется загрузка изображения в файловое хранилище через функцию **uploadImageToStorage()**, после чего ссылка на изображение сохраняется в записи исследования.

3.3.3. Модуль формирования пояснительного текста

Для формирования пояснительного текста в системе используется локальная языковая модель Qwen-2.5-7B-Instruct [35], развёрнутая через платформу Ollama [34]. Использование локальной модели позволяет обрабатывать медицинские данные без передачи информации во внешние облачные сервисы, что повышает уровень конфиденциальности.

Взаимодействие с моделью осуществляется через API-маршрут /api/airecommendation. После завершения анализа система автоматически формирует запрос к языковой модели на основе результатов исследования.

При построении запроса учитываются:

- результат классификации изображения;
- уровень уверенности модели;
- результаты расчёта CURB-65;
- основные сведения о пациенте и исследовании.

На основе этих данных формируется структурированный prompt, который передаётся языковой модели для генерации пояснительного текста. Для повышения стабильности генерации используется параметр temperature = 0.3, позволяющий получать более последовательные и предсказуемые ответы.

Сформированный текст не является медицинским заключением и рассматривается исключительно как вспомогательная информация для врача. Итоговое решение о диагнозе и тактике лечения принимает медицинский специалист.

К ограничениям использования языковой модели относятся возможные неточности формулировок, зависимость качества ответа от входных данных и отсутствие гарантии медицинской достоверности сгенерированного текста. По этой причине результаты работы модели используются только в качестве дополнительного инструмента поддержки принятия решений.

3.3.4. Интеграция ИИ ассистента

Для обеспечения контролируемого взаимодействия пользователя с системой в API-маршруте **/api/chat** используется системный prompt, который формируется перед каждым обращением к ассистенту.

В системный prompt автоматически добавляются результаты выполненного исследования, включая диагноз и уровень уверенности модели. Благодаря этому ответы консультанта формируются с учётом текущего анализа, а не только на основе вопроса пользователя.

Дополнительно prompt содержит набор правил, определяющих формат и содержание ответов. В частности, задаётся фиксированная структура ответа, требования к медицинской терминологии и ограничения на генерацию потенциально опасных рекомендаций. Ассистенту запрещается назначать конкретные схемы лечения и дозировки препаратов, а также выдавать окончательные медицинские заключения без участия врача.

Для обработки пользовательских запросов используется структура сообщений (messages), состоящая из системного prompt и текущего сообщения пользователя.

История переписки сохраняется на стороне клиента с использованием механизма sessionStorage браузера. Это позволяет сохранять контекст консультации в рамках текущей пользовательской сессии.

3.3.5. Модуль генерации тепловой карты

Генерация тепловой карты реализована посредством API-маршрута **/api/heatmap**. Данный модуль построен как отдельный вычислительный компонент, объединяющий серверную часть Next.js [32] и Python-скрипт, отвечающий за построение визуализации.

После получения изображения API выполняет проверку формата файла и сохраняет его во временный каталог. Далее сервер Node.js [31] запускает

Python-скрипт **generate_heatmap.py** с использованием функции **spawn()** из модуля **child_process**, передавая пути к входному и выходному файлам в качестве аргументов командной строки.

Python-скрипт загружает обученную модель **DenseNet121** и выполняет построение тепловой карты методом Grad-CAM [33]. Для этого используются карты признаков последнего сверточного блока сети и вычисленные градиенты целевого класса. Полученная карта активности масштабируется до размеров исходного изображения и накладывается поверх рентгеновского снимка с использованием цветовой палитры JET.

После завершения обработки Python сохраняет результат в файл и завершает выполнение. Node.js отслеживает код завершения процесса и при успешном выполнении считывает сформированное изображение. Для уменьшения объёма передаваемых данных дополнительно выполняется сжатие изображения посредством библиотеки Sharp [26].

Сформированная тепловая карта преобразуется в формат Base64 и возвращается клиентской части в составе JSON-ответа. После завершения операции временные файлы автоматически удаляются.

3.3.6. Модули управления пациентами

Для работы с пациентами используются маршруты **/api/patients** и **/api/patients/{id}**.

В начале каждого запроса сервер получает идентификатор текущего пользователя через session_id и функцию **getUserBySession()**. Далее этот идентификатор используется для выполнения операций только с данными текущего врача.

Маршрут GET **/api/patients** выполняет получение списка пациентов или поиск по имени через параметр search. Создание новой карточки реализовано через POST **/api/patients**, где данные формы передаются в функцию **createPatient()** и сохраняются в базе данных.

Для работы с конкретного пациента используется маршрут **/api/patients/{id}**. При выполнении GET сервер загружает данные пациента через **getPatientById()** и связанную историю исследований через **getPatientAnalyses()**. Обновление информации реализовано методом PATCH, который использует функцию **updatePatient()**.

Перед получением или изменением данных дополнительно проверяется принадлежность пациента текущему врачу посредством сравнения **patient.doctor_id** и **user.id**, что исключает доступ к чужим медицинским записям.

3.3.7. Модуль управления медицинскими записями

Для хранения и управления медицинскими записями пациентов реализован маршрут **/api/medical-records**, поддерживающий операции получения и создания записей.

Метод GET используется для получения списка медицинских записей. При наличии параметра patientId выполняется выборка записей конкретного пациента, в противном случае возвращаются все записи врача.

Метод POST предназначен для создания новой медицинской записи. Перед сохранением сервер проверяет наличие обязательных полей (patient_id, record_type, record_date, title), а также выполняет дополнительную проверку принадлежности пациента текущему врачу через запрос к таблице patients.

После успешной проверки формируется объект медицинской записи с уникальным идентификатором (UUID) и сохраняется в таблицу **medical_records**. Помимо основной информации о пациенте запись может содержать лабораторные показатели (WBC, RBC, CRP, ESR, Procalcitonin и другие), жизненно важные параметры (SpO_2, температура, частота дыхания, артериальное давление), результаты обследований, врачебные заметки и ссылки на прикреплённые файлы.

3.3.8. Модуль анализа медицинской записи пациента

Для автоматического анализа медицинской записи пациента реализован маршрут **/api/analyze-medical-records**.

На основе полученных данных формируется единый текстовый контекст, содержащий сведения о сопутствующих заболеваниях, принимаемых препаратах, аллергиях, вредных привычках, лабораторных показателях, результатах обследований и врачебных заметках. Для каждой записи дополнительно указывается дата её создания, что позволяет модели учитывать динамику изменений показателей.

Сформированный контекст передаётся в языковую модель в составе детализированного промпта. В промпте задаётся фиксированная структура ответа, включающая краткое резюме состояния пациента, оценку факторов риска, анализ лабораторных показателей, возможные диагнозы, рекомендации по дальнейшему обследованию и мониторингу состояния.

После завершения анализа сервер автоматически определяет итоговый уровень риска пациента (low, moderate, high, critical) на основании сформированного ответа модели. Полученный текст анализа вместе с уровнем риска и количеством обработанных медицинских записей сохраняется в таблице **ai_medical_analyses**, что обеспечивает возможность последующего просмотра истории ранее выполненных анализов.

3.3.9. Модуль истории исследований

Для получения списка ранее выполненных исследований в системе реализован маршрут **/api/history**, работающий по методу GET.

При обработке запроса сервер сначала получает значение session_id из cookie и выполняет проверку пользовательской сессии. После успешной аутентификации из параметров запроса извлекаются значения limit и offset,

используемые для ограничения количества записей и поддержки постраничной загрузки данных.

Далее выполняется SQL-запрос к таблице **analyses**, который выбирает сведения об исследованиях пользователя, включая идентификатор пациента, результат классификации, уровень уверенности модели, дату анализа, пояснительный текст и ссылку на сохранённое изображение. Результаты сортируются по полю created_at в порядке убывания, благодаря чему первыми отображаются наиболее новые исследования.

После завершения выборки сервер формирует JSON-ответ и передаёт его клиентской части приложения для последующего отображения истории исследований.

3.3.10. Модуль управления последующим наблюдением пациентов

Для управления записями последующего наблюдения реализован маршрут **/api/followups**.

Метод GET используется для получения списка записей последующего наблюдения. Данные извлекаются из таблицы **follow_ups** с помощью SQL-запроса и сортируются по дате назначения. Для каждой записи дополнительно выполняется получение информации о пациенте, его последних исследованиях и медицинских записях. После объединения данных сервер формирует расширенный объект и возвращает его клиентскому приложению в формате JSON.

Метод POST предназначен для создания новой записи последующего наблюдения. Сервер получает идентификатор пациента, дату повторного визита, комментарии врача и при необходимости ссылку на связанное исследование. После проверки входных данных вызывается функция **createFollowUp()**, которая сохраняет новую запись в базе данных и возвращает созданный объект клиентской части приложения.

Для изменения состояния записи используется маршрут **/api/follow-ups/[id]**, реализующий HTTP-метод PATCH. После получения идентификатора записи из параметров маршрута сервер принимает новый статус из тела запроса и обновляет соответствующую запись в базе данных через функцию **updateFollowUp()**. В системе поддерживаются статусы scheduled, completed, cancelled и missed, что позволяет врачу фиксировать результаты проведения контрольных визитов и отслеживать их текущее состояние.

3.3.11. Модуль консультаций

Для реализации механизма врачебных консультаций в системе разработаны маршруты **/api/second-opinions** и **/api/second-opinions/[id]**.

Маршрут **/api/second-opinions** используется для создания и получения запросов на консультацию.

Метод POST предназначен для создания нового запроса на консультацию. Сервер принимает идентификатор исследования (analysisId), идентификатор врача-консультанта (reviewingDoctorId) и комментарий инициатора запроса (requestNotes). После проверки существования исследования создаётся запись в таблице **second_opinions** с уникальным идентификатором, начальным статусом pending, датой создания и информацией об участниках консультации.

Метод GET используется для получения списка консультаций. Для формирования ответа применяется SQL-запрос с объединением таблиц **second_opinions**, analyses и users.

Маршрут **/api/second-opinions/[id]** предназначен для работы с конкретной консультацией.

Метод GET выполняет получение полной информации о выбранной консультации. Для этого используется SQL-запрос с объединением таблиц

second_opinions, analyses и patients, что позволяет одновременно получить сведения о пациенте, исследовании и параметрах консультации.

Метод PATCH используется для обработки результата консультации. Сервер динамически формирует SQL-запрос UPDATE на основе переданных полей и сохраняет заключение врача-консультанта, включая диагноз, уровень уверенности и текстовые комментарии. При переводе консультации в статус completed дополнительно автоматически записывается дата завершения в поле reviewed_at.

3.3.12. Модуль статистики

Маршрут **/api/statistics** предназначен для получения агрегированных статистических данных, связанных с работой врача и результатами проведённых исследований.

После проверки пользовательской сессии через session_id сервер получает идентификатор текущего врача и выполняет параллельное получение данных с использованием конструкции Promise.all(). Для формирования статистики используются функции **getDoctorStatistics()**, **getAnalysesTrend()** и **getAnalysesTrendWithSeverity()**, которые обращаются к базе данных и выполняют необходимые вычисления.

API поддерживает параметр days, позволяющий получать статистику за различные временные интервалы. На основании переданного значения формируются временные ряды для построения графиков и диаграмм.

В результате работы маршрута клиент получает сводную информацию о количестве пациентов, выполненных исследований, выявленных случаев пневмонии, распределении заболеваний по степени тяжести, а также данные для построения аналитических графиков. Все данные возвращаются в формате JSON и используются для последующей визуализации на странице статистики.

3.4. Интеграция модели машинного обучения

После завершения обучения модель DenseNet121 была экспортирована из среды TensorFlow/Keras в формат ONNX [24] с помощью библиотеки tf2onnx. Полученная модель используется в серверной части системы для автоматического анализа рентгеновских изображений.

Процесс инференса включает несколько последовательных этапов:

- загрузку рентгеновского снимка пользователем;
- предварительную обработку изображения, включающую изменение размера до 224×224 пикселей и нормализацию значений пикселей;
- передачу подготовленного изображения в ONNX-модель;
- получение вероятностей классов Normal и Pneumonia;
- формирование итогового результата и его отображение пользователю.

Для выполнения инференса используется библиотека ONNX Runtime [25], а предварительная обработка изображений реализована с помощью библиотеки Sharp [26]. При этом параметры обработки изображений полностью соответствуют этапу подготовки данных во время обучения модели, что обеспечивает корректность и стабильность результатов анализа.

Использование ONNX позволило интегрировать модель машинного обучения в единую программную систему и обеспечить быстрый анализ рентгеновских изображений без необходимости запуска отдельных сервисов машинного обучения.

3.5. Оценка степени тяжести с использованием шкалы CURB-65

Помимо анализа рентгеновских изображений, в разработанной системе используется шкала CURB-65 [10], предназначенная для клинической оценки степени тяжести пневмонии и риска развития осложнений.

Необходимость использования данного подхода связана с тем, что модель машинного обучения выполняет анализ только рентгеновского снимка и не учитывает клинические показатели пациента. Для получения более полной оценки состояния пациента в систему был интегрирован дополнительный механизм клинической оценки.

Шкала CURB-65 основана на пяти параметрах:

- нарушение сознания пациента (Confusion);
- уровень мочевины в крови более 7 ммоль/л (Urea);
- частота дыхания не менее 30 вдохов в минуту (Respiratory Rate);
- снижение артериального давления (Blood Pressure);
- возраст пациента 65 лет и старше (Age ≥ 65).

Каждый из перечисленных параметров оценивается в один балл. После суммирования баллов определяется общий уровень риска:

- 0–1 балл — низкий риск;
- 2 балла — средний риск;
- 3–5 баллов — высокий риск.

Расчёт выполняется автоматически после ввода клинических данных пациента через интерфейс системы. Полученный результат используется для дополнительной интерпретации состояния пациента и помогает врачу оценить необходимость дальнейшего наблюдения или госпитализации.

3.6. База данных системы

Для хранения данных в разработанной системе используется реляционная база данных PostgreSQL [27]. Выбор данной СУБД обусловлен её надёжностью, поддержкой сложных связей между сущностями и удобством работы со структурированными медицинскими данными. Администрирование базы данных выполнялось с использованием среды pgAdmin [28].

Структура базы данных была спроектирована с учётом особенностей хранения медицинской информации, результатов анализа изображений и взаимодействия между врачами. ER-диаграмма базы данных представлена в Приложении Б.2.

База данных включает следующие основные сущности:

- users: хранение информации о пользователях системы;
- sessions: хранение пользовательских сессий и данных авторизации;
- patients: хранение сведений о пациентах;
- analyses: результаты анализа рентгеновских изображений;
- ai_medical_analyses: пояснительные тексты, сформированные AI-модулем;
- medical_records: медицинские записи пациентов;
- follow_ups: данные последующего наблюдения пациентов;
- second_opinions: запросы на получение второго врачебного мнения.

Основные связи между таблицами:

- Один пользователь (users) может работать с несколькими пациентами (patients).
- Один пациент (patients) может иметь несколько исследований (analyses).
- Один пациент (patients) может иметь несколько медицинских записей (medical_records).
- Один пациент (patients) может иметь несколько последующих наблюдений (follow_ups).
- Одно исследование (analyses) может быть связано с несколькими запросами на получение второго мнения (second_opinions).
- Результаты исследования могут использоваться для формирования пояснительных текстов, которые сохраняются в таблице (ai_medical_analyses).

Для обеспечения целостности данных используются:

- первичные ключи (Primary Key);
- внешние ключи (Foreign Key);
- ограничения уникальности (например, для адреса электронной почты пользователя);
- обязательное заполнение критически важных полей (NOT NULL);
- каскадное удаление отдельных связанных записей (ON DELETE CASCADE).

3.7. Система сравнения результатов исследований

При выборе нескольких исследований пользователь может просматривать:

- результаты классификации;
- вероятность наличия пневмонии;
- изменения CURB-65;
- пояснительный текст;
- тепловые карты;
- изменения медицинских показателей.

Функция сравнения помогает оценивать динамику заболевания и результаты проводимого лечения.

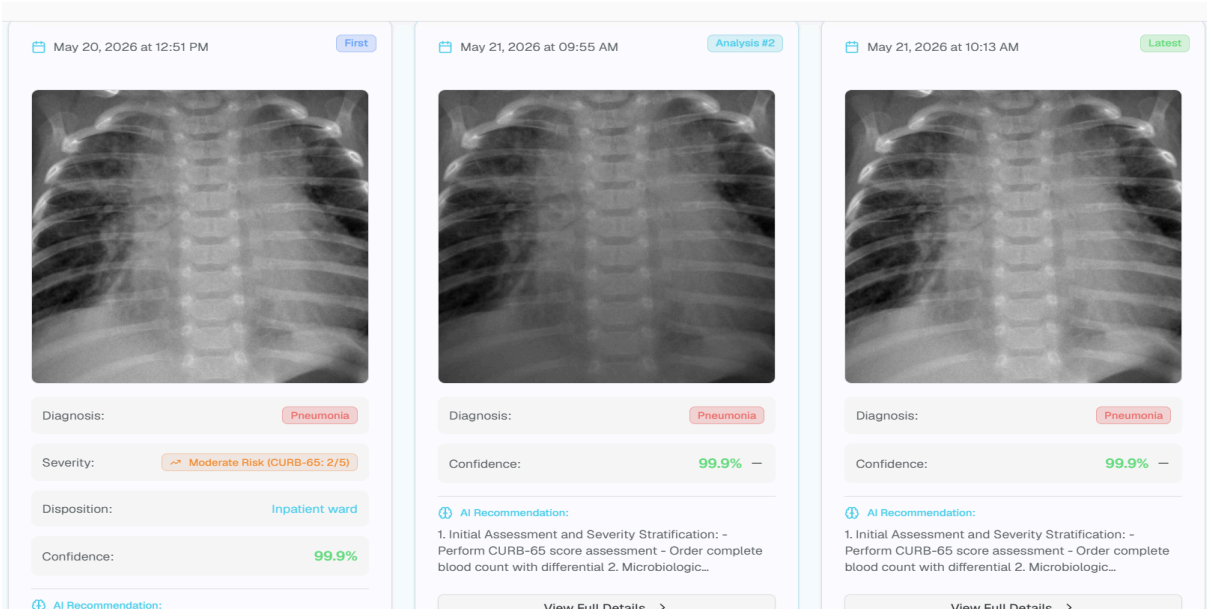


Рисунок 22 — Интерфейс сравнения результатов нескольких исследований пациента

3.8. Настольная версия системы

Помимо веб-версии, в рамках проекта была реализована настольная версия приложения. Для этого использовалась платформа ElectronJS [36], которая позволяет создавать desktop-приложения на основе веб-технологий. Такой подход удобен, поскольку основная часть интерфейса и логики может быть переиспользована из веб-приложения.

Использование ElectronJS также позволяет в дальнейшем расширить возможности локальной работы приложения. Например, можно настроить интеграцию с локальными файлами, локальным хранилищем или внутренней инфраструктурой медицинского учреждения. При этом настольная версия сохраняет общую архитектуру системы и использует те же основные модули анализа изображений.

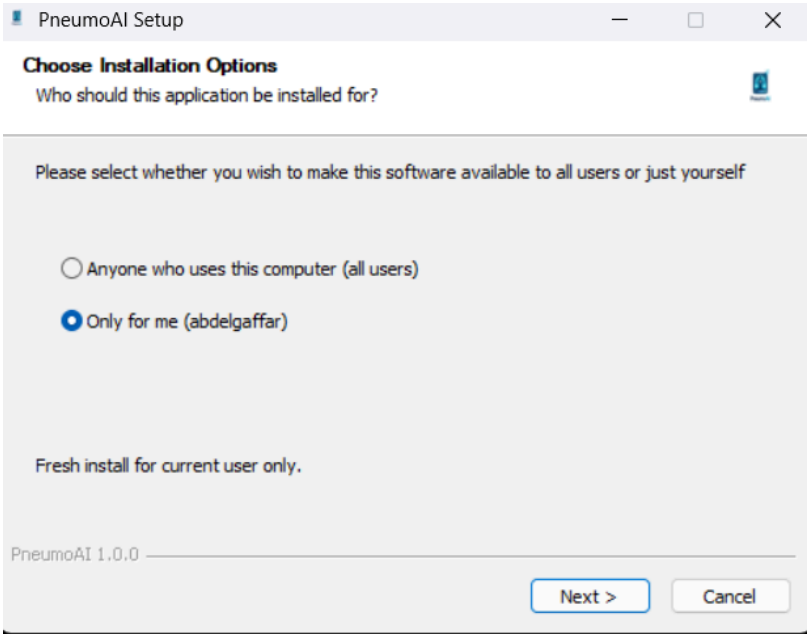


Рисунок 23 — Интерфейс установки настольного приложения

Одним из преимуществ desktop-версии является возможность локального запуска AI-компонентов системы, включая Ollama [35] и модель

Qwen2.5-7B-Instruct [35], без необходимости использования внешних облачных сервисов. Это особенно важно при работе с конфиденциальными медицинскими данными.

3.9. Ограничения исследования

При выполнении работы были выявлены следующие ограничения:

- для обучения моделей использовался открытый датасет Chest X-Ray Pneumonia Dataset, размещённый на платформе Kaggle;
- используемый набор данных содержит ограниченное количество изображений и не охватывает всё разнообразие случаев, встречающихся в клинической практике;
- исследование проводилось на заранее подготовленных данных и не включало тестирование на снимках из реальных медицинских учреждений;
- разработанная система не внедрялась в рабочие процессы медицинских организаций и не использовалась в условиях реальной эксплуатации;
- результаты анализа могут содержать ошибки классификации, характерные для моделей машинного обучения;
- система предназначена для поддержки врача при анализе рентгеновских изображений и не может использоваться в качестве самостоятельного средства постановки диагноза.

Указанные ограничения могут быть устранены в дальнейшем за счёт расширения набора данных, проведения клинической валидации и тестирования системы в условиях медицинских учреждений.

ЗАКЛЮЧЕНИЕ

В рамках выполнения выпускной квалификационной работы было разработано веб-приложение для диагностики и оценки рисков пневмонии по рентгеновским снимкам и клиническим данным с помощью методов машинного обучения. Система позволяет автоматически выявлять признаки пневмонии на рентгеновских снимках и предоставляет врачу дополнительную информацию для интерпретации результатов исследования.

В ходе выполнения исследования было проведено сравнение нескольких архитектур глубокого обучения, применяемых для анализа медицинских изображений. Результаты экспериментов показали, что модель DenseNet121 обеспечивает высокую точность классификации. Поэтому именно эта модель была выбрана для дальнейшего использования в разработанной системе.

Практическая значимость работы заключается в создании единой программной платформы, объединяющей автоматический анализ изображений, оценку состояния пациента по шкале CURB-65, формирование пояснительного текста, визуализацию результатов с помощью тепловых карт и хранение медицинской информации. Разработанное решение может использоваться как вспомогательный инструмент для поддержки врача при анализе рентгеновских исследований.

Элементом новизны разработанного решения является объединение результатов анализа медицинских изображений с клинической оценкой состояния пациента в рамках одной системы. Дополнительно реализована возможность формирования пояснительного текста на основе результатов исследования и визуальная интерпретация решений модели с использованием тепловых карт.

Следует отметить, что разработанная система является исследовательским прототипом. Для обучения использовался открытый

набор данных Chest X-Ray Pneumonia Dataset, который не охватывает всё разнообразие клинических случаев. Кроме того, система не проходила клиническую апробацию и не тестировалась в условиях реального медицинского учреждения. По этой причине результаты работы модели не могут рассматриваться как самостоятельное диагностическое заключение и должны использоваться только в качестве вспомогательного инструмента, который может помочь специалисту при анализе рентгеновских изображений и принятии решений.

В перспективе проект может быть доработан за счёт расширения набора данных, проведения клинической апробации на независимых выборках, дальнейшего повышения качества моделей машинного обучения, а также интеграции системы в существующие медицинские информационные системы.

Результаты работы опубликованы в репозитории GitLab:
https://git.kpfu.ru/AkhAbdelgaffar/pneumonia-detection

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Pneumonia // World Health Organization. – URL: https://www.who.int/news-room/fact-sheets/detail/pneumonia (дата обращения: 31.05.2026).
2. Goodfellow, I. Deep Learning / I. Goodfellow, Y. Bengio, A. Courville. – Cambridge : MIT Press, 2016. – 800 p.
3. LeCun, Y. Gradient-Based Learning Applied to Document Recognition / Y. LeCun, L. Bottou, Y. Bengio, P. Haffner // Proceedings of the IEEE. – 1998. – Vol. 86, № 11. – P. 2278–2324.
4. Huang, G. Densely Connected Convolutional Networks / G. Huang, Z. Liu, L. van der Maaten, K. Q. Weinberger // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. – 2017. – P. 4700–4708. – URL: https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html (дата обращения: 31.05.2026).
5. He, K. Deep Residual Learning for Image Recognition / K. He, X. Zhang, S. Ren, J. Sun // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. – 2016. – P. 770–778. – URL: https://arxiv.org/abs/1512.03385 (дата обращения: 31.05.2026).
6. Tan, M. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks / M. Tan, Q. V. Le // Proceedings of the 36th International Conference on Machine Learning. – 2019. – P. 6105–6114. – URL: https://arxiv.org/abs/1905.11946 (дата обращения: 31.05.2026).
7. Sandler, M. MobileNetV2: Inverted Residuals and Linear Bottlenecks / M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L. C. Chen // Proceedings of the IEEE Conference on Computer Vision and Pattern

Recognition. – 2018. – P. 4510–4520. – URL: https://arxiv.org/abs/1801.04381 (дата обращения: 31.05.2026).

8. Mooney, P. Chest X-Ray Images (Pneumonia) // Kaggle. – URL: https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia (дата обращения: 31.05.2026).
9. Kermany, D. S. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning / D. S. Kermany, M. Goldbaum, W. Cai [et al.] // Cell. – 2018. – Vol. 172, № 5. – P. 1122–1131. – URL: https://pubmed.ncbi.nlm.nih.gov/29474911/ (дата обращения: 31.05.2026).
10. Lim, W. S. Defining Community Acquired Pneumonia Severity on Presentation to Hospital: an International Derivation and Validation Study / W. S. Lim, M. M. van der Eerden, R. Laing [et al.] // Thorax. – 2003. – Vol. 58, № 5. – P. 377–382. – URL: https://thorax.bmj.com/content/58/5/377 (дата обращения: 31.05.2026).
11. Qure.ai. – URL: https://www.qure.ai (дата обращения: 31.05.2026).
12. InferVision. – URL: https://www.infervision.com (дата обращения: 31.05.2026).
13. Lunit. – URL: https://www.lunit.io (дата обращения: 31.05.2026).
14. Aidoc. – URL: https://www.aidoc.com (дата обращения: 31.05.2026).
15. TensorFlow Documentation. – URL: https://www.tensorflow.org/api_docs (дата обращения: 31.05.2026).
16. Keras Documentation. – URL: https://keras.io/api/ (дата обращения: 31.05.2026).
17. OpenCV Documentation. – URL: https://docs.opencv.org/ (дата обращения: 31.05.2026).
18. NumPy Documentation. – URL: https://numpy.org/doc/ (дата обращения: 31.05.2026).

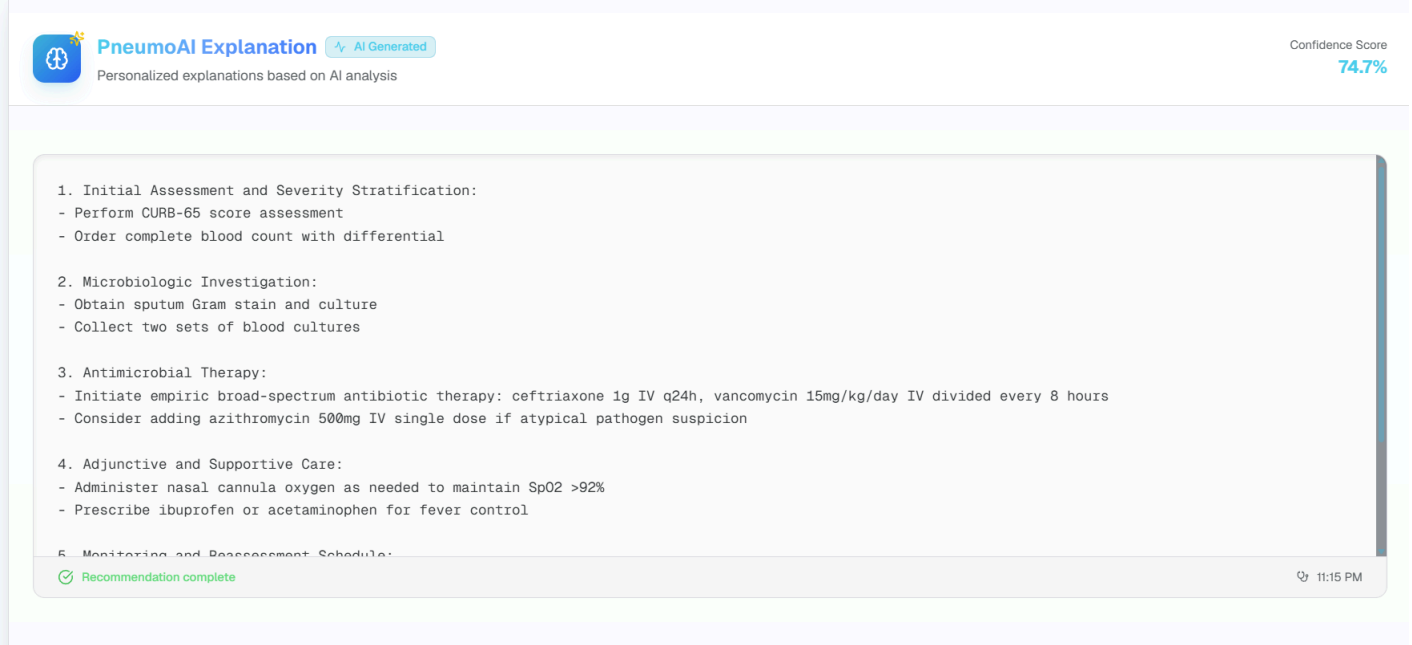
19. Kingma, D. P. Adam: A Method for Stochastic Optimization / D. P. Kingma, J. Ba. – URL: https://arxiv.org/abs/1412.6980 (дата обращения: 31.05.2026).
20. DenseNet121 // Keras Applications. – URL: https://keras.io/api/applications/densenet/ (дата обращения: 31.05.2026).
21. EfficientNetB0 // Keras Applications. – URL: https://keras.io/api/applications/efficientnet/ (дата обращения: 31.05.2026).
22. ResNet50 // Keras Applications. – URL: https://keras.io/api/applications/resnet/ (дата обращения: 31.05.2026).
23. MobileNetV2 // Keras Applications. – URL: https://keras.io/api/applications/mobilenet/ (дата обращения: 31.05.2026).
24. Open Neural Network Exchange (ONNX). – URL: https://onnx.ai/ (дата обращения: 31.05.2026).
25. ONNX Runtime Documentation. – URL: https://onnxruntime.ai/docs/ (дата обращения: 31.05.2026).
26. Sharp Documentation. – URL: https://sharp.pixelplumbing.com/ (дата обращения: 31.05.2026).
27. PostgreSQL Documentation. – URL: https://www.postgresql.org/docs/ (дата обращения: 31.05.2026).
28. pgAdmin Documentation. – URL: https://www.pgadmin.org/docs/ (дата обращения: 31.05.2026).
29. FIPS PUB 180-4. Secure Hash Standard (SHS). – National Institute of Standards and Technology. – URL: https://csrc.nist.gov/publications/detail/fips/180/4/final (дата обращения: 31.05.2026).

30. HTTP Cookies // MDN Web Docs. – URL: https://developer.mozilla.org/en-US/docs/Web/HTTP/Cookies (дата обращения: 31.05.2026).
31. Node.js Documentation. – URL: https://nodejs.org/docs/latest/api/ (дата обращения: 31.05.2026).
32. Next.js Documentation. – URL: https://nextjs.org/docs (дата обращения: 31.05.2026).
33. Selvaraju, R. R. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization / R. R. Selvaraju, M. Cogswell, A. Das [et al.] // Proceedings of the IEEE International Conference on Computer Vision. – 2017. – P. 618–626. – URL: https://arxiv.org/abs/1610.02391 (дата обращения: 31.05.2026).
34. Ollama Documentation. – URL: https://github.com/ollama/ollama (дата обращения: 31.05.2026).
35. Qwen2.5 Technical Report. – URL: https://arxiv.org/abs/2412.15115 (дата обращения: 31.05.2026).
36. Electron Documentation. – URL: https://www.electronjs.org/docs/latest/ (дата обращения: 31.05.2026).

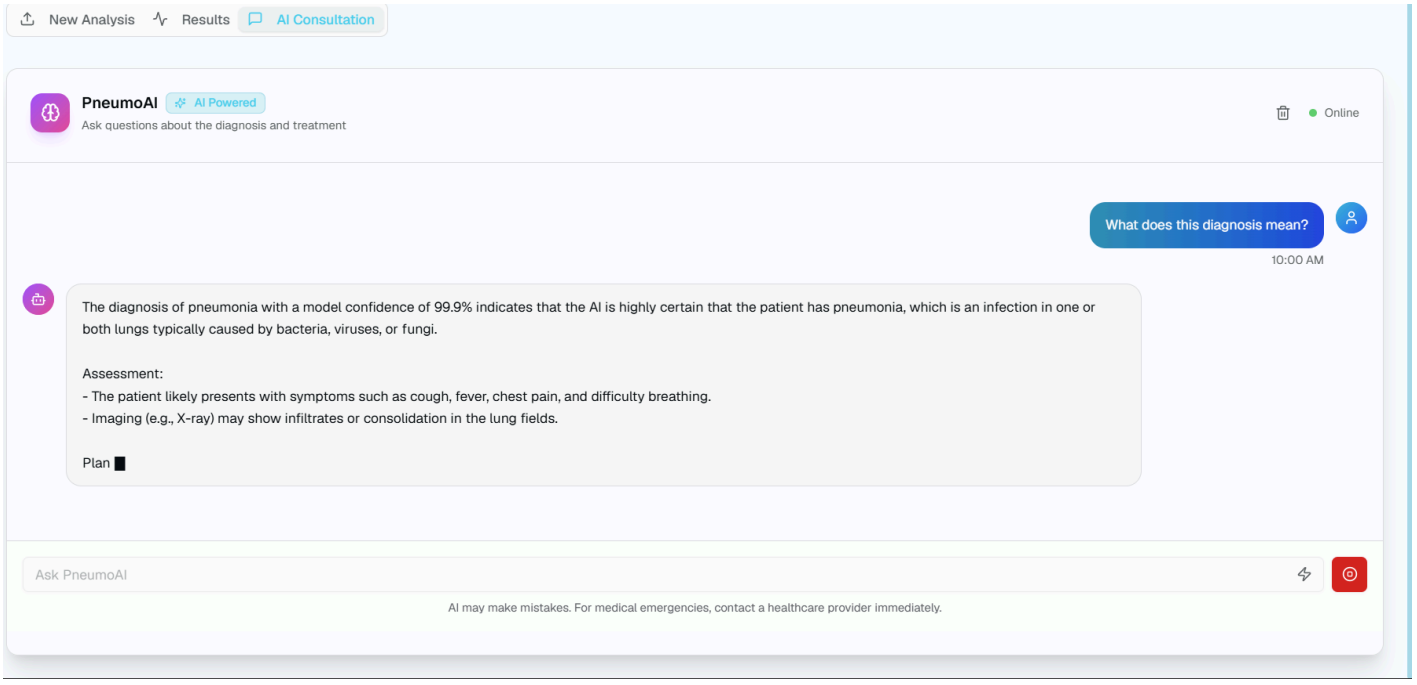
Приложение

Приложение А. Интерфейсы разработанной системы

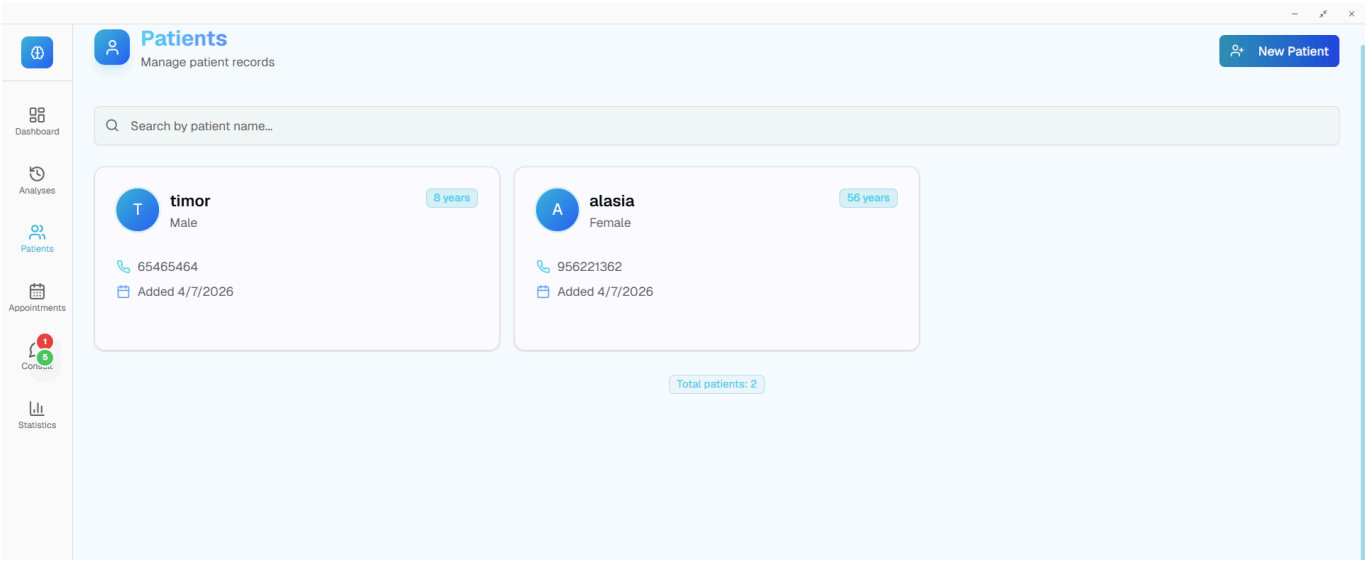
А.1 Интерфейс пояснительного текста



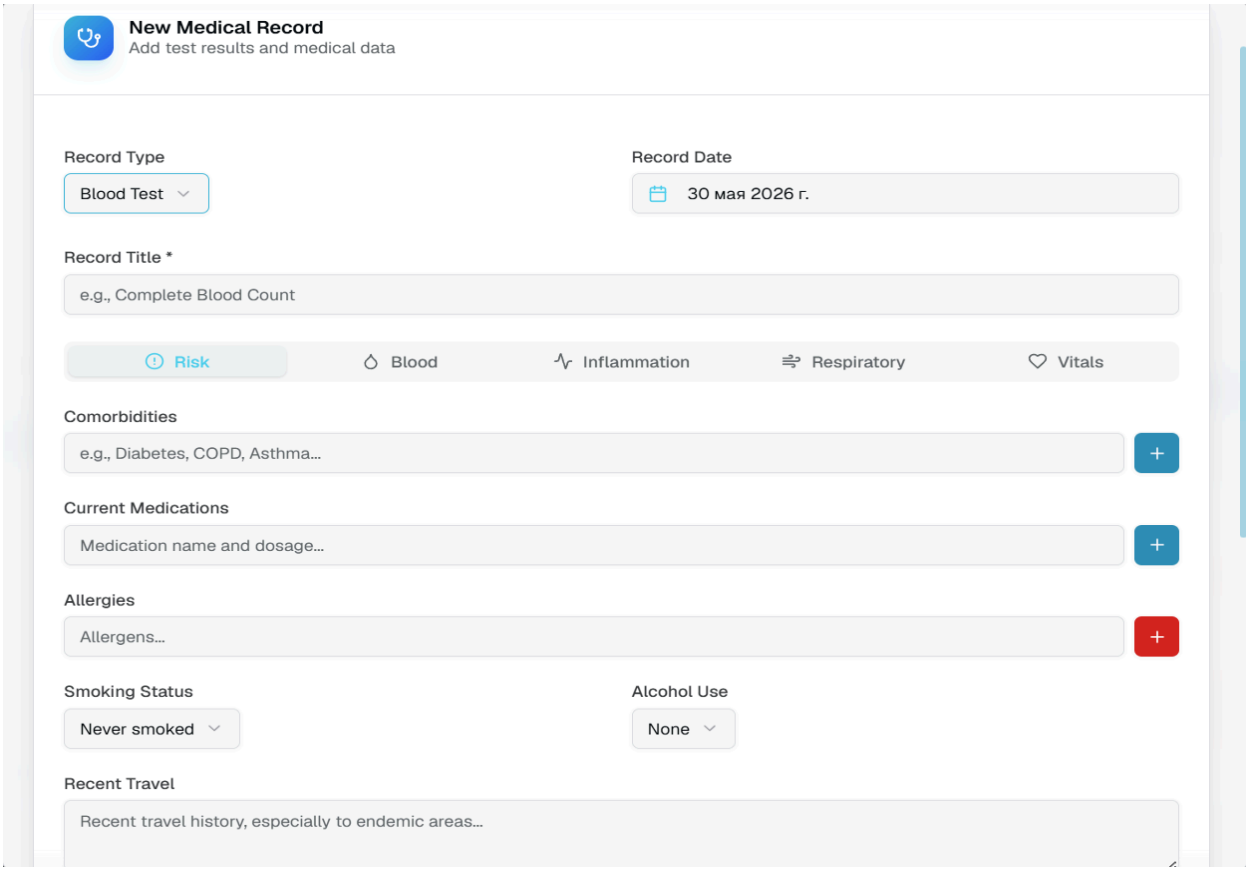
А.2 Интерфейс ИИ ассистента



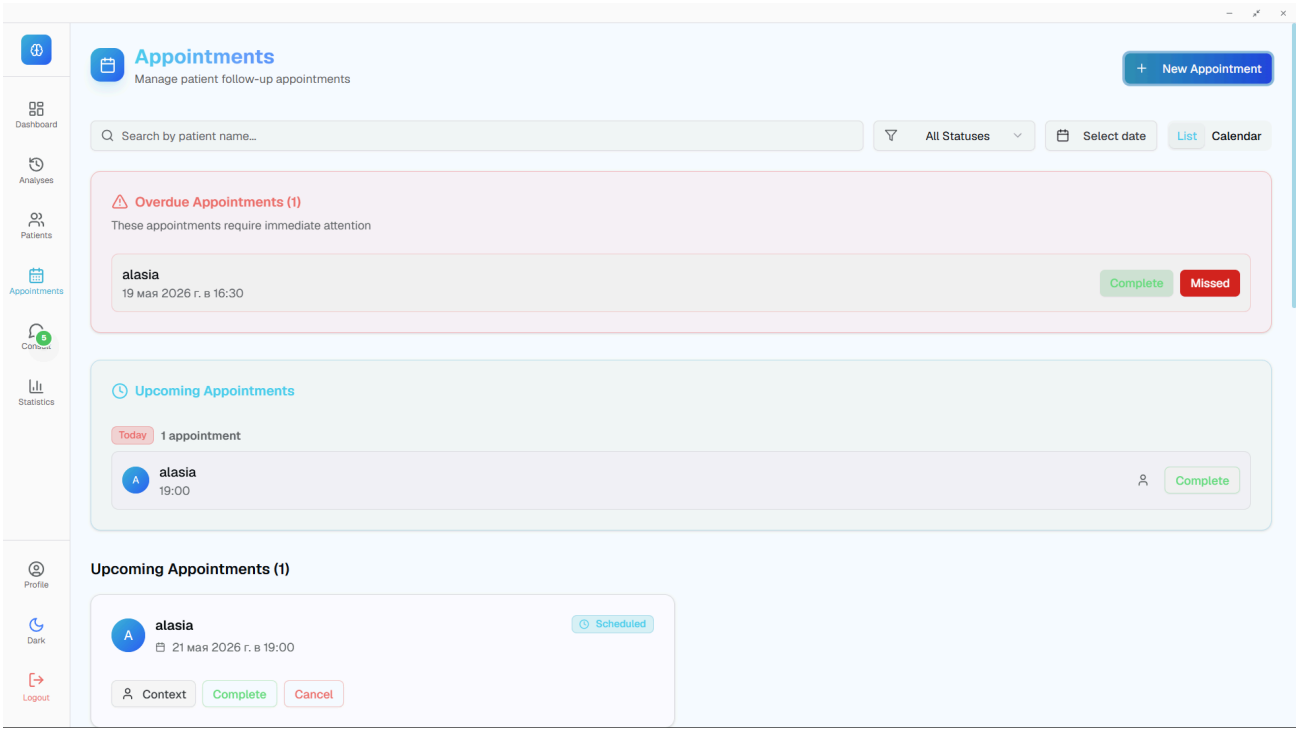
А.3 Страница управления пациентами



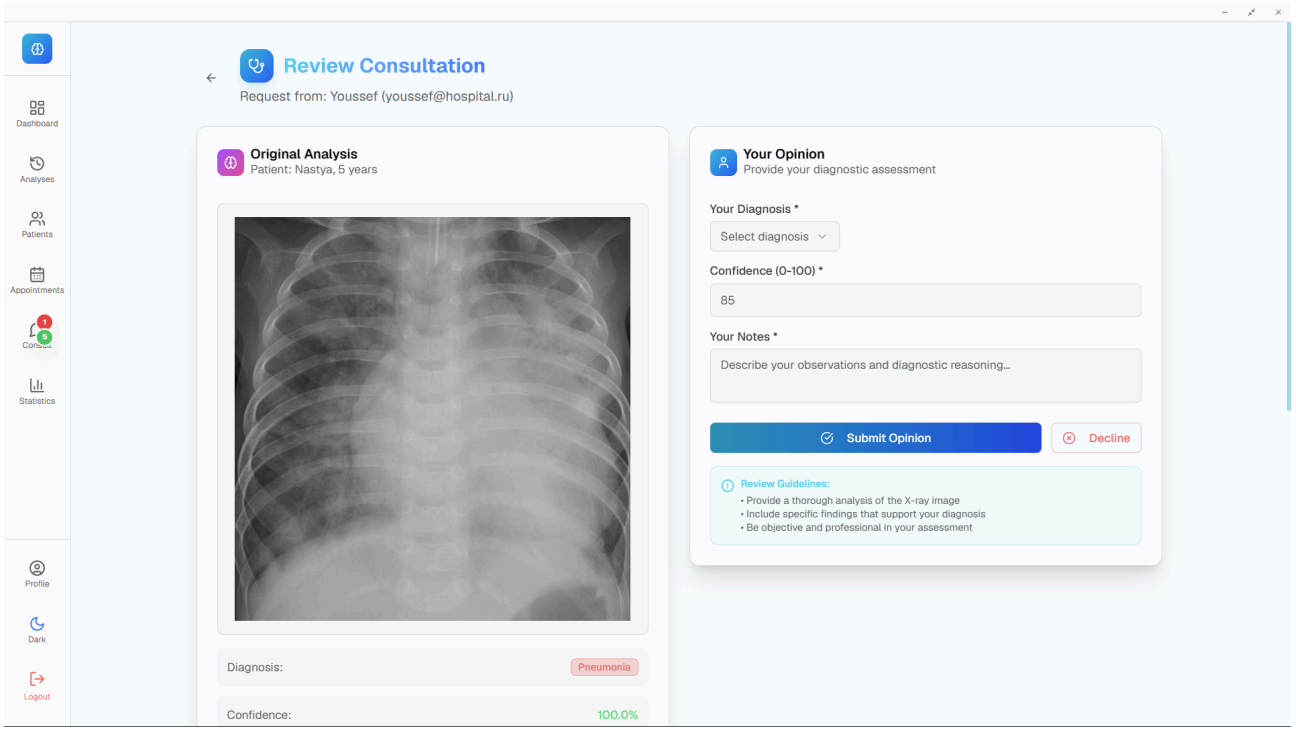
А.4 Интерфейс создания медицинской записи



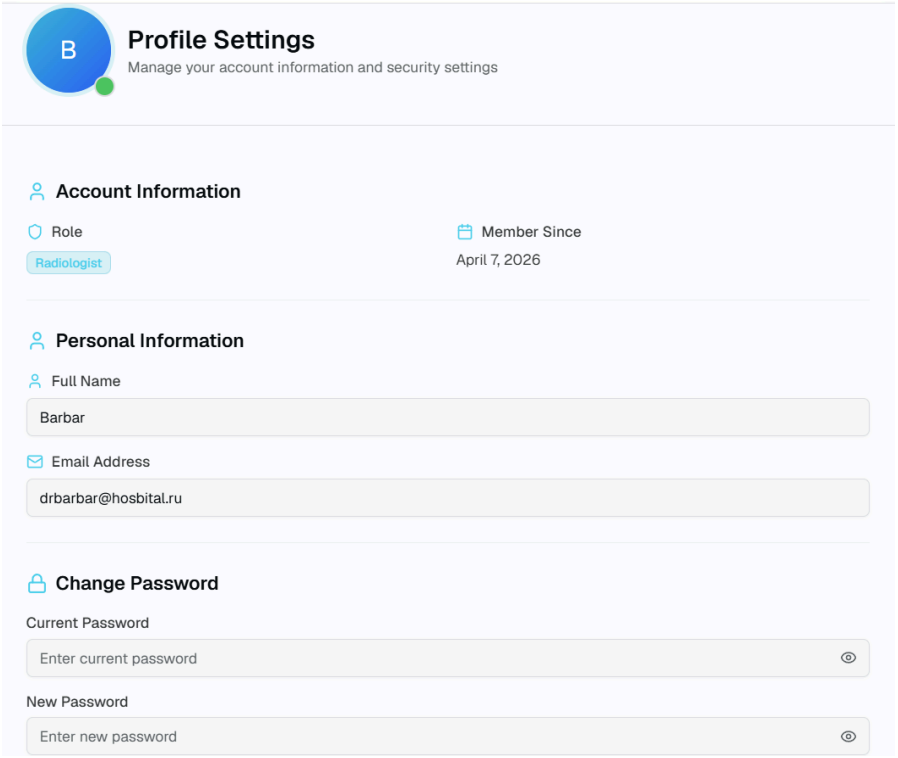
A.5 Интерфейс follow-up наблюдений



A.6 Страница собственного мнения в системе консультации

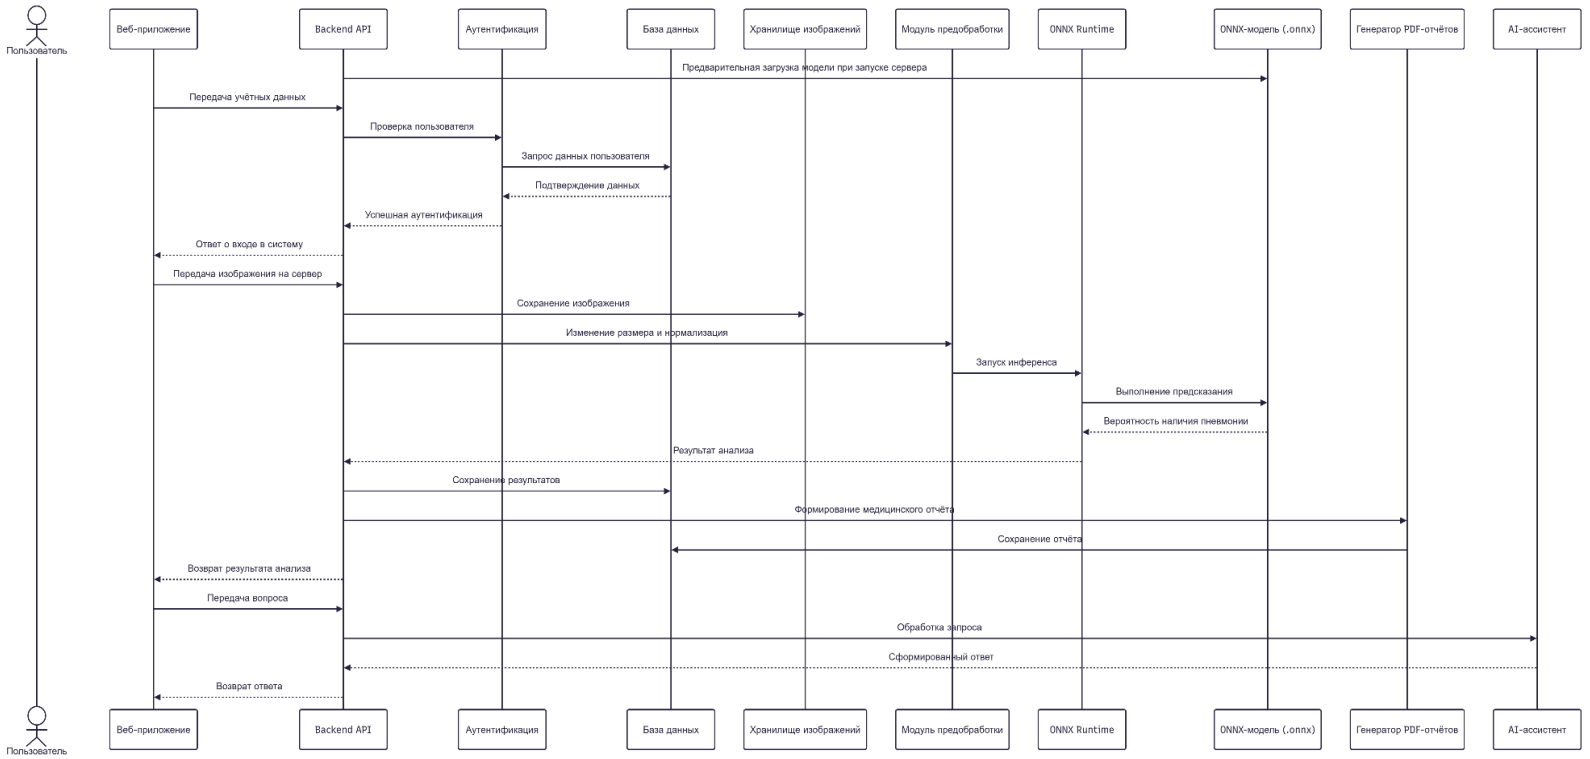


А.7 Страница профиля пользователя



Приложение Б. Структура системы и базы данных

Б.1 Общая архитектура системы



Б.2 ER-диаграмма базы

